

Boston Housing Data korrelaatiokertoimet

Harjoitustyö opintojaksolle Laskennalliset menetelmät ja bayesilaisuuden perusteet
DATA.STAT.430

Julia Vihtelin

2025-12-07

Sisällysluettelo

1. Johdanto
2. Datan esittely
3. Bootstrap -menetelmä
4. Tulokset ja niiden tulkinta

Johdanto

Tässä dokumentissa suoritetaan harjoitustyö kurssille DATA.STAT.430, Laskennalliset menetelmät ja bayesilaisuuden perusteet. Harjoitustyö on suoritettu Rstudion RMarkdownilla. Harjoitustyössä tutkitaan R:n aineistoa “Boston Housing Data” Bootstrap menetelmällä.

Datan esittely

Datana toimii Boston Housing Data (MASS-paketista), joka käsittelee asuntojen arvoja Bostonin lähiöissä. Data on kerätty Bostonin esikaupunkialueilta vuonna 1970. Sitä on koonnut ensimmäisenä Harrison & Rubinfeld tutkimuksessaan vuonna 1978. Boston-data sisältää 506 asuinalueetta (tracts) sekä runsaasti muuttujia. Tässä työssä muuttujina toimivat:

lstat: Matalan sosioekonomisen aseman väestön osuus (%) medv: Omistusasuntojen mediaanihinta (1000 USD)

Bootstrap -menetelmä

Bootstrap -menetelmässä pyritään hyödyntämään havaintoaineistoa mahdollisimman paljon, ilman ulkopuolisia malleja. Menetelmässä poimitaan satunnaisesti havaintoja otoksesta ja näin voidaan laskea tunnuslukuja uudelleenpoimituista otoksista. Otoksen poiminnassa halutaan otos, joka on täsmälleen alkuperäisen otoksen suuruinen ja poiminta tehdään palauttaen. Tämä tuottaa bootstrap -otoksen. Kun poimintaa toistetaan useasti saadaan tunnuslukujen jakauma eli bootstrap jakauma.

Harjoitustyössä käytän Bootstrap -menetelmää korrelaatiokertoimien bootstrap estimaatteihin ja luottamusväliin, kun parametreinä ovat “lstat” ja “medv”.

```

library(MASS)
data("Boston")

### Korrelaatiokertoimien bootstrap- estimaatti ja -luottamusväli

set.seed(314)
B <- 1999
n <- nrow(Boston)
theta_star <- numeric(B)

for (i in 1:B) {
  ind <- sample(1:n, n, replace = TRUE) # Bootstrap-otos
  theta_star[i] <- cor(Boston$lstat[ind], Boston$medv[ind]) # Otokorrelaatio
}

theta_hat <- cor(Boston$lstat, Boston$medv) # Alkuperäinen estimaatti
theta_hat

## [1] -0.7376627

theta_bar <- mean(theta_star) # Bootstrap jakauma keskiarvo
theta_bar

## [1] -0.7386225

2*theta_hat - theta_bar # Harhakorjattu estimaatti

## [1] -0.736703

PI <- quantile(theta_star, c(0.025, 0.975)) # Prosenttipisteväli
PI

##          2.5%          97.5%
## -0.7672357 -0.7072799

### Histogrammi

hist(theta_star,
      breaks = 40,
      main = "Bootstrap-jakauma korrelaatiolle (lstat-medv)",
      xlab = "Bootstrap-estimoitu korrelaatio",
      col = "lightgray", border = "white")

# Alkuperäinen korrelaatio
abline(v = theta_hat, col = "red", lwd = 2)

# Bootstrap-luottamusväli
abline(v = PI[1], col = "blue", lwd = 2, lty = 2)
abline(v = PI[2], col = "blue", lwd = 2, lty = 2)


legend("topright",

```

```

legend = c("Alkuperäinen korrelaatio", "95% CI rajat"),
col = c("red", "blue"),
lwd = 2, lty = c(1, 2))

```



Tulokset ja niiden tulkinta

Theta_hat eli $\hat{\theta}$ on alkuperäinen estimaatti korrelaatiokertoimesta. Se saa arvoksi -0.7376 , mikä kertoo, että köyhemmillä alueilla asuntojen arvon mediaani laskee huomattavasti.

Theta_bar $\bar{\theta}$ on bootstrap -jakauman keskiarvo -0.7386 , mikä on hyvin lähellä alkuperäistä arvoa eli harha on minimaalinen.

Harhakorjattu estimaatti on -0.7367 , joten voidaan todeta, ettei bootstrap paljasta merkittävää harhaa.

Luottamusväli $[-0.7672, -0.7073]$ on kapea ja kokonaan negatiivinen eli korrelaatio on selvästi negatiivinen.

Histogrammista voidaan todeta jakauman olevan hieman vasemmalle vinossa, eli data venyy hieman keskiarvon vasemmalle puolelle. Punainen viiva näyttää, miten hyvin bootstrap -jakauma vastaa alkuperäistä estimaattia eli kuinka pieni harha on.