

Rikollisuus USA:ssa

Harjoitustyö opintojaksolle DATA.STAT.450 Monimuuttujamenetelmät

Julia Vihtelin

2025-02-13

Sisällysluettelo

1. Johdanto
2. Datan esittely
3. Käytetyt menetelmät
 1. Pääkomponenttianalyysi
 2. Faktorianalyysi
4. Tulokset ja niiden tulkinta PCA
5. Tulokset ja niiden tulkinta EFA
6. Yhteenveto
7. Lähteet

Johdanto

Tämä dokumentti on kevään 2025 harjoitustyö opintojaksolle DATA.STAT.450, Monimuuttujamenetelmät. Tämä harjoitustyö on tehty Rstudion R Markdown:lla. Harjoitustyössä hyödynnetään pääkomponenttianalyysiä sekä faktorianalyysiä R:n dataan USArrests.

Datan esittely

Datana tässä harjoitustyössä toimii R-kirjaston data "USArrests", jossa muuttujina ovat rikokset murha, pahoinpitely ja raiskaus, joita kuvataan pidätykset 100 000 asukasta kohden. Lisäksi muuttujana on osuus väestöstä, joka asuu kaupungissa. Näitä muuttujia mitataan eri Yhdysvaltojen osavaltioissa. Työssä hyödynnetään kaikkia muuttujia.

```
# Pääkomponenttianalyysi aineistoon  
  
data("USArrests") # Aineisto  
head(USArrests)   # Näytä ensimmäiset rivit
```

##	Murder	Assault	UrbanPop	Rape
## Alabama	13.2	236	58	21.2
## Alaska	10.0	263	48	44.5
## Arizona	8.1	294	80	31.0
## Arkansas	8.8	190	50	19.5
## California	9.0	276	91	40.6
## Colorado	7.9	204	78	38.7

```
summary(USArrests) # Yhteenveto muuttujista
```

```
##      Murder      Assault      UrbanPop      Rape
## Min.   : 0.800   Min.    : 45.0   Min.    :32.00   Min.    : 7.30
## 1st Qu.: 4.075   1st Qu.:109.0   1st Qu.:54.50   1st Qu.:15.07
## Median : 7.250   Median :159.0   Median :66.00   Median :20.10
## Mean   : 7.788   Mean    :170.8   Mean    :65.54   Mean    :21.23
## 3rd Qu.:11.250   3rd Qu.:249.0   3rd Qu.:77.75   3rd Qu.:26.18
## Max.   :17.400   Max.    :337.0   Max.    :91.00   Max.    :46.00
```

```
S <- cov(USArrests) # Kovarianssimatriisi
v <- eigen(S)
eigenva <- print(v$va) # Ominaisarvot
```

```
## [1] 7011.114851 201.992366 42.112651 6.164246
```

```
eigenve <- print(v$ve) # Ominaisvektorit
```

```
##      [,1]      [,2]      [,3]      [,4]
## [1,] -0.04170432 0.04482166 0.07989066 0.99492173
## [2,] -0.99522128 0.05876003 -0.06756974 -0.03893830
## [3,] -0.04633575 -0.97685748 -0.20054629 0.05816914
## [4,] -0.07515550 -0.20071807 0.97408059 -0.07232502
```

```
pca_result <- prcomp(USArrests, scale. = TRUE)
summary(pca_result)
```

```
## Importance of components:
##              PC1      PC2      PC3      PC4
## Standard deviation 1.5749 0.9949 0.59713 0.41645
## Proportion of Variance 0.6201 0.2474 0.08914 0.04336
## Cumulative Proportion 0.6201 0.8675 0.95664 1.00000
```

```
print(pca_result$rotation) # Tulostetaan PCA:n ominaisvektorit
```

```
##      PC1      PC2      PC3      PC4
## Murder -0.5358995 -0.4181809 0.3412327 0.64922780
## Assault -0.5831836 -0.1879856 0.2681484 -0.74340748
## UrbanPop -0.2781909 0.8728062 0.3780158 0.13387773
## Rape -0.5434321 0.1673186 -0.8177779 0.08902432
```

```
pca_scores <- as.data.frame(pca_result$x) # Muunnetaan PCA-tulokset data.frame-muotoon
```

```
colnames(pca_scores) <- paste("PC", 1:ncol(pca_scores), sep = "") # Nimetään sarakkeet
```

```
head(pca_scores)
```

	PC1	PC2	PC3	PC4
Alabama	-0.9756604	-1.1220012	0.43980366	0.154696581
Alaska	-1.9305379	-1.0624269	-2.01950027	-0.434175454
Arizona	-1.7454429	0.7384595	-0.05423025	-0.826264240
Arkansas	0.1399989	-1.1085423	-0.11342217	-0.180973554
California	-2.4986128	1.5274267	-0.59254100	-0.338559240
Colorado	-1.4993407	0.9776297	-1.08400162	0.001450164

```
library(ggplot2)
```

```
## Warning: package 'ggplot2' was built under R version 4.3.3
```


```
pc1_direction <- pca_result$rotation[, 1] # Ensimmäinen pääkomponentti

# Lasketaan viivan kulmakerroin
slope <- pc1_direction[3] / pc1_direction[1] # PC3/PC1

# Lasketaan viivan keskipiste, jotta se kulkee datan keskeltä
mean_PC1 <- mean(pca_scores$PC1)
mean_PC3 <- mean(pca_scores$PC3)

# Piirretään scatterplot ja lisätään PC1:n suuntainen viiva
ggplot(pca_scores, aes(x = PC1, y = PC3)) +
  geom_point() +
  geom_abline(intercept = mean_PC3 - slope * mean_PC1, slope = slope,
              color = "red", linewidth = 1) +
  ggtitle("Pääkomponenttianalyysin tulokset PC1 vs. PC3") +
  xlab("Pääkomponentti 1") +
  ylab("Pääkomponentti 3") +
  theme_minimal()
```

Pääkomponenttianalyysin tulokset PC1 vs. PC3



Käytetyt menetelmät

Tässä koodissa on suoritettu pääkomponenttianalyysi ja havainnollistettu tätä kuvaajalla, jossa alkuperäisten datapisteiden sijainti näytetään pääkomponenttiavaruudessa, jossa akseleina ovat komponentit 1 ja 3. Kuvaajassa esiintyy myös pääkomponentin 1 suunta (punainen suora), jolla pisteiden hajonta on suurin. Toisena menetelmänä käytetään faktorianalyysiä, jossa etsitään faktoreita, jotka selittävät muuttujien vaihtelua ja näin tulkitaan tuloksia (KvantiMOTV; faktorianalyysi). Tuloksia havainnollistetaan Factor loadings -kuvaajalla.

Pääkomponenttianalyysi

Tässä käytetään pääkomponenttianalyysiä, jonka tavoitteena on kuvata ne komponentit, jolle data tuottaa suurimmat varianssit. Analyysissä siis muodostetaan lineaarikombinaatioita muuttujista. Pääkomponentit selkeyttää suurta aineistoa. Analyysi asettaa komponentit suuruusjärjestykseen ominaisarvojen mukaan. (Wikipedia.org; Pääkomponenttianalyysi, Nummi; Multivariate Analysis)

Eksploratiivinen faktorianalyysi

Faktorianalyysin tavoitteena on tunnistaa korreloituneiden muuttujien taustalla olevat suhteet (T.Nummi). Faktorianalyysi tuottaa faktorilatauksen, joka selittää kuinka paljon faktorin avulla pystytään selittämään muuttujien vaihtelua (KvantiMOTV; faktorianalyysi).

Tulokset ja niiden tulkinta PCA

Taulukossa esiintyy neljä pääkomponenttia. Jokaisella rikoksella on kohtalaisen suuri lataus ensimmäiseen pääkomponenttiin, mikä saattaisi tarkoittaa pääkomponentin mittaavan esim. yleistä rikollisuustasoa. Toisella pääkomponentilla on latausta UrbanPop- muuttujaan ja vähän rikoksiin, joten se saattaisi kuvata kaupunkiasutuksen yhteyttä rikollisuuteen. Kolmannella pääkomponentilla on suurin (negatiivinen) lataus Rape -muuttujaan ja neljännellä Murder ja Assault - muuttujiin.

Kuvaaja todistaa myös ensimmäisen pääkomponentin selittävän suurimman osan datan varianssista, kuten myös keskihajonta kertoo. Ensimmäinen pääkomponentti selittää n.62 % varianssista.

```
# Suoritetaan faktorianalyysi aineistolle
```

```
data(USArrests)
```

```
scaled_data <- scale(USArrests)
```

```
# Suoritetaan faktorianalyysi ilman rotaatiota
```

```
fa_result <- factanal(scaled_data, factors = 1)
```

```
fa_result_varimax <- factanal(scaled_data, factors = 1, rotation = "varimax") # Faktorianalyysi Varimax  
print(fa_result_varimax)
```

```
##
```

```
## Call:
```

```
## factanal(x = scaled_data, factors = 1, rotation = "varimax")
```

```
##
```

```
## Uniquenesses:
```

```
##   Murder  Assault UrbanPop   Rape  
##   0.332    0.042    0.931    0.534
```

```
##
```

```
## Loadings:
```

```
##           Factor1  
## Murder    0.818  
## Assault   0.979  
## UrbanPop  0.262  
## Rape      0.683
```

```
##
```

```
##           Factor1  
## SS loadings      2.162  
## Proportion Var   0.540
```

```
##
```

```
## Test of the hypothesis that 1 factor is sufficient.
```

```
## The chi square statistic is 9.15 on 2 degrees of freedom.
```

```
## The p-value is 0.0103
```

```
fa_result_promax <- factanal(scaled_data, factors = 1, rotation = "promax") # Faktorianalyysi Promax-ro  
print(fa_result_promax)
```

```
##
```

```
## Call:
```

```
## factanal(x = scaled_data, factors = 1, rotation = "promax")
```

```
##
```


```
## Uniquenesses:
##   Murder  Assault UrbanPop   Rape
##   0.332   0.042   0.931   0.534
##
## Loadings:
##           Factor1
## Murder    0.818
## Assault   0.979
## UrbanPop  0.262
## Rape     0.683
##
##           Factor1
## SS loadings    2.162
## Proportion Var  0.540
##
## Test of the hypothesis that 1 factor is sufficient.
## The chi square statistic is 9.15 on 2 degrees of freedom.
## The p-value is 0.0103
```

```
# Visualisoidaan lataukset ja faktorin kuormittaminen
factor_loadings_varimax <- fa_result_varimax$loadings
factor_loadings_promax <- fa_result_promax$loadings
```

```
# Luodaan visualisointi latauksista
```

```
loadings_data <- data.frame(
  Variables = rownames(factor_loadings_varimax),
  Varimax = factor_loadings_varimax[,1],
  Promax = factor_loadings_promax[,1]
)
```

```
ggplot(loadings_data, aes(x = Variables)) +
  geom_bar(aes(y = Varimax), stat = "identity", position = "dodge", fill = "blue", alpha = 0.6) +
  geom_bar(aes(y = Promax), stat = "identity", position = "dodge", fill = "red", alpha = 0.6) +
  labs(title = "Factor Loadings: Varimax vs Promax Rotation", y = "Loadings", x = "Variables") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Tulokset ja niiden tulkinta EFA

Faktoriin liittyy eniten muuttujat "assault" ja "murder". "Urbanpop" muuttuja liittyy heikosti faktoriin sekä uniqueness on korkea, joten suurin osa sen vaihtelusta ei selity tällä faktorilla. Faktorin kanssa korreloi vahvasti murder, assault ja rape. Assaultin uniqueness on 0.042, joten faktori/piilevä tekijä selittää lähes kaiken vaihtelun. Kuvaajasta näkyy myös, kuinka suuret lataukset muuttujilla on. Täten assault muuttuja on erittäin keskeinen osa kontekstissa. Rotaatioilla ei ole vaikutusta sillä, on vain yksi selkeä faktori. Aineisto on yksinkertainen ja sen vuoksi analyysi ei tuo runsaasti tietoa.

Yhteenveto

Pääkomponenttianalyysi on suotuisa analyysikeino tähän aineistoon sillä muuttujat ovat korreloituneita. PCA:n avulla nähdään eroavaisuudet Urbanpop:n ja rikosten välillä sekä voidaan päätellä rikosten yhteyksiä esiintyvyydessä. Faktorianalyysissä olisi mielekkäämpää olla enemmän kuin 4 muuttujaa, jotta rotaatioilla nähtäisiin eroavaisuuksia. Faktorianalyysin kuvaajan muodostaminen oli haastavaa yhdellä faktorilla. Kuitenkin faktorianalyysi paljasti, että jokin piilevä tekijä selittää Assault -muuttujaa huomattavasti.

Lähteet

Alvin C.Rencher, William F.Christensen. 7.10.2012. "Methods of Multivariate Analysis". John Wiley & Sons.

KvantiMOTV. (2024). "Faktorianalyysi". <https://www.fsd.tuni.fi/menetelmaopetus/faktori/faktori.html>.

Tapio Nummi. "Multivariate Analysis". Lecture slides from course multivariate analysis DATA.STAT.450 2025. p. 41-84.

Wikipedia.org. “Pääkomponenttialyysi”. 17.12.2024. <https://fi.wikipedia.org/wiki/P%C3%A4%C3%A4komponenttialyysi>.