

Julia Vihtelin

FREKVENSsiaINEISTOJEN LOG-LINEAARiset MALLIT

Kandidaattitutkielma
Informaatioteknologian ja viestinnän tiedekunta
Toukokuu 2026

TIIVISTELMÄ

Julia Vihtelin

Frekvenssiaineistojen log-lineaariset mallit

Kandidaattitutkielma

Tampereen yliopisto

Matematiikan ja tilastollisen data-analyysin tutkinto-ohjelma

Toukokuu 2026

Log-lineaariset mallit ovat yleistettyjä lineaarisia malleja, joilla voidaan mallintaa kategoristen muuttujien välisiä yhteyksiä. Malleja vertaillessa voidaan valita joko täysin riippumaton malli tai assosiaatiotermejä sisältävä malli. Tällöin yksi tai useampi muuttuja, kuitenkin maksimissaan ristiintaulukon astelukumäärä, ovat yhteydessä keskenään. Täydellisessä eli saturoidussa mallissa esiintyy kaikki mahdolliset vuorovaikutukset. Tarkasteltavaa mallia voidaan verrata saturoituun malliin, jotta nähdään, ovatko kaikki vuorovaikutukset oleellisia aineiston tarkastelun kannalta.

Tutkielmassa käsitellään Poisson-jakaumaan perustuvien log-lineaaristen mallien teoriaa ja sovelletaan tätä terveydenhuoltotilastoja käsittelevään aineistoon. Tutkimusaineisto on kategorinen aineisto, jossa havainnot luokitellaan useisiin kategorioihin. Tarkasteltavan datan faktorimuuttujia ovat diagnoosi, hyvinvointialue, palvelusektori ja vuosi.

Tutkimusaineiston tarkastelu aloitetaan muokkaamalla se muotoon, jossa havaintoarvot ovat omassa sarakkeessaan nimeltä lukumäärä. Lisäksi dataa siistitään poistamalla ylimääräiset rivit ja sarakkeet. Tämän jälkeen voidaan aloittaa datan tarkastelu sovittamalla ja vertailemalla malleja. Vertailussa on oleellista devianssin ja vapausasteiden muutos, joiden perusteella valitaan malli, joka sopii aineistoon riittävän hyvin. Datan siistiminen ja analysointi suoritetaan R-ohjelmistolla.

Tutkielman tavoitteena on arvioida log-lineaarista mallinnusta eri asteisissa ristiintaulukoissa. Mallintamalla aineistoa etsitään muuttujien välisiä yhteyksiä. Kaksiulotteisessa analyysissä tutkitaan vuoden ja palvelusektorien käyntimäärien yhteyttä khi-neliötestillä ja log-lineaarisilla malleilla. Kolmiulotteisessa mallinnuksessa syvennyttään diagnoosien lukumäärien yleisyyden muutokseen eri palvelusektoreilla. Lisäksi tutkitaan, miten arvot muuttuvat vuosittain. Neljännen muuttujan lisäämisen myötä voidaan tarkastella muuttujien välistä yleistä riippuvuusrakennetta sekä aineistossa esiintyvää ylihajontaa.

Mallien sopivuutta arvioidaan sekä mosaiikki- että hajontakuvioiden avulla. Mallin valinnan jälkeen sen estimoituja arvoja verrataan havaittuihin arvoihin hajontakuvion avulla. Lisäksi lasketaan itseisarvoltaan suurimmat residuaalit ja tulkitaan näiden arvojen kategorioita. Standardoidut residuaalit näyttävät jokaisen solun estimoidun arvon poikkeaman todellisesta arvosta. Lopuksi esitetään kaikki residuaalit sovitettujen arvojen funktiona.

Avainsanat: log-lineaarinen mallinnus, frekvenssiaineisto, Poisson-jakauma, ristiintaulukko, khi-neliötesti

Tämän julkaisun alkuperäisyys on tarkastettu Turnitin Originality -ohjelmalla.

SISÄLLYS

1	JOHDANTO	1
2	AINEISTO JA KAKSIULOTTEINEN ANALYYSI	2
2.1	KATEGORINEN AINEISTO	2
2.2	TUTKIMUSAINESTO	3
2.3	KAKSIULOTTEISTEN RISTIINTAULUKOIDEN KHI-NELIÖTESTAUS	5
2.4	KAKSIULOTTEISTEN RISTIINTAULUKOIDEN MALLINNUS	8
3	LOG-LINEAARISEN MALLIN TEORIAA	14
3.1	POISSON-JAKAUMA JA LOG-LINKKIFUNKTIO	14
3.2	ESTIMOINTITEORIAA	15
3.3	MALLIN SOVITUS	17
4	MONIULOTTEINEN LOG-LINEAARINEN ANALYYSI	19
4.1	KOLMIULOTTEISTEN RISTIINTAULUKOIDEN MALLINNUS	19
4.2	NELIULOTTEISTEN RISTIINTAULUKOIDEN MALLINNUS	22
5	YHTEENVETO	26
	LÄHTEET	28
	LIITE A: R-KOODIT	29
	LIITE B: AINEISTON MUUTTUJAT	32
	B.0.1 DIAGNOOSIT	32
	B.0.2 HYVINVOINTIALUEET	33

TEKOÄLYN KÄYTTÖ TÄSSÄ TYÖSSÄ

Opinnäytteessäni on käytetty tekoälysovelluksia:

- ☒ Kyllä
☐ Ei

Ilmoitukseni mukaan olen käyttänyt opinnäytteessäni tutkielmanprosessin aikana seuraavia tekoälysovelluksia:

Sovellus	Versio
ChatGPT	GPT -5.3-mini

TEKOÄLYN KÄYTTÖTARKOITUS

Tekoälyä on käytetty opinnäytteen kirjoitusprosessissa tekstin kielelliseen muotoiluun ja kieliopin tarkistamiseen. Lisäksi tekoälyä on käytetty R-koodin virheenkorjauksessa ja parantamisessa, kun käsiteltiin kuvaajia ja alkuperäisen aineiston muokkaamista.

OSIOT, JOISSA TEKOÄLYÄ ON KÄYTETTY

Yleinen kieliopin korjaus ja ilmaisujen selkeyttäminen sekä hajontakuvioihin, residuaalikuvaajiin ja aineiston rakenteen muokkaamiseen liittyvän R-koodin virheenkorjaus ja parantaminen.

RISKIEN TIEDOSTAMINEN

Olen tietoinen siitä, että olen täysin vastuussa koko opinnäytteeni sisällöstä, mukaan lukien osat, joiden tuottamisessa on hyödynnetty tekoälyä, ja hyväksyn vastuun mahdollisista tästä seuranneista eettisten ohjeiden rikkomuksista.

1 JOHDANTO

Log-lineaariset mallit ovat tilastollisia malleja, jotka kuuluvat yleistettyihin lineaarisiiin malleihin. Malleilla kuvataan frekvenssejä tai suhteellisia frekvenssejä muuttujien avulla. Yksi niiden keskeisistä käyttötarkoituksista on solufrekvenssien mallintaminen ristiintaulukoissa, joissa luokitellaan kategorisia vastemuuttujia. Mallin parametreilla kuvataan yhteyksiä kategoristen muuttujien välillä. [2, s.193]

Poissonin log-lineaarinen malli olettaa satunnaismuuttujan olevan Poisson-jakautunut ja käyttävän log-linkkifunktiota. Lukumääräaineistojen oletetaan usein noudattavan Poisson-jakaumaa, koska ne ovat epänegatiivisia kokonaislukuja. [2, s.73] Log-linkkifunktiolla tarkoitetaan luonnollisen logaritmin ottamista solufrekvenssin estimaatista [17, s.26].

Poisson-jakauman varianssi ja odotusarvo oletetaan yhtä suuriksi, mitä kutsutaan tasapainohajonnaksi (engl. *equidispersion*). Kuitenkin joskus varianssi saattaa olla suurempi kuin odotusarvo, jolloin puhutaan ylihajonnasta. [11] Mikäli ylihajontaa esiintyy, Poisson-jakauma ei selitä aineistoa hyvin. Tätä voidaan tutkia hajontaparametrilla, joka kuvaa devianssin ja vapausasteiden suhdetta. Ylihajontaa esiintyy, jos hajontaparametrin arvo on suurempi kuin yksi. [10, s.232]

Log-lineaarinen mallinnus perustuu pää- ja assosiaatiovaikutusten tutkimiseen. Analyysissä muuttujia ei erotella selittäviin ja vastemuuttujiin, vaan kaikkia muuttujia käsitellään tasavertaisina. Menetelmän tavoitteena on löytää parhaimmin aineistoa kuvaava malli vertaamalla supistettua mallia (engl. *reduced model*) saturoituun malliin. [13, s.2]

Log-lineaarisen analyysin kannalta aineiston oikeanlainen rakenne on keskeinen, sillä analyysi perustuu frekvensseihin tai niiden suhteellisiin osuuksiin. Solufrekvenssit tulee esittää aineistossa erillisenä muuttujana, vaikka aineisto olisi alun perin esitetty ristiintaulukkomuodossa.

Aineiston tarkastelu alkaa mallin valinnalla, minkä jälkeen estimoidaan mallin parametrit ja arvioidaan estimaattien tarkkuutta. Lisäksi mallin sopivuutta arvioidaan vertaamalla sovitettuja arvoja havaittuihin arvoihin. Parametriestimaateiksi valitaan arvot, jotka minimoivat käytetyn sovituksen hyvyyden (engl. *goodness of fit*) kriteerit. [12, s. 38–40]

Tämän tutkielman aineisto on terveydenhuollon asiakaskäynneistä koostuva frekvenssiaineisto, joka on saatu Terveyden ja hyvinvoinnin laitoksen avoimesta tilastopalvelusta [14]. Tarkoituksena on tutkia kategoristen muuttujien yhteyksiä havaintoaineistossa. Tutkielma aloitetaan pohjustuksella kategoriseen aineistoon ja kaksiulotteiseen ristiintaulukkokoon. Tämän jälkeen käsitellään log-lineaarisen mallituksen teoriaa ja lopuksi sovelletaan tätä tutkimusaineistoon moniulotteisella tarkastelulla. Useamman muuttujan samanaikaisella tarkastelulla saadaan monipuolisempi käsitys riippuvuusrakenteista.

2 AINEISTO JA KAKSIULOTTEINEN ANALYYSI

2.1 KATEGORINEN AINEISTO

Frekvenssiaineistoilla tarkoitetaan dataa, joka koostuu havaintoarvojen lukumääristä, frekvensseistä. Frekvenssejä esitetään yleensä ristiintaulukoissa, jotka ovat yksinkertaisimmillaan muotoa, jossa toinen muuttuja on riveillä ja toinen sarakkeilla. Tätä kutsutaan kaksiulotteiseksi ristiintaulukoksi.[8, s.52]

Tarkastellaan ristiintaulukkoa, jossa on I riviä ja J saraketta sekä IJ solua. Tarkasteltava frekvenssi solussa (i, j) on y_{ij} , kun faktoreiksi on määritelty muuttujat X ja Y . Faktorimuuttujien kategoriat ovat tällöin $X_1, X_2, \dots, X_I$ ja $Y_1, Y_2, \dots, Y_J$. Todennäköisyys sille, että tarkasteltava kohde kuuluu muuttujan X kategoriaan i on p_{i0} ja vastaavasti muuttujan Y kategoriaan j on p_{0j} . Täten näiden kahden tapahtuman ollessa riippumattomia, molempien samanaikainen tapahtuminen on näiden todennäköisyyksien tulo $p_{ij} = p_{i0}p_{0j}$. Todennäköisyyksien estimaateiksi saadaan $\widehat{p}_{i0} = y_{i0}/y_{00}$ ja $\widehat{p}_{0j} = y_{0j}/y_{00}$. [16, s.41-42]

Riippumattomassa mallissa (engl. *independence model*) $(I \times J)$ -taulukolle on olemassa $I + J - 1$ rajoitetta. IJ solufrekvenssillä ja $I + J - 1$ rajoitteella on olemassa $IJ - (I + J - 1) = (I - 1)(J - 1)$ vapausastetta odotusarvoille. [16, s.43] Kaksiulotteisissa log-lineaarisissa malleissa esiintyvät parametrit sekä niiden lukumäärät on esitetty taulukossa 2.1. Päävaikutusparametrit kuvaavat yksittäisten muuttujien vaikutuksia solufrekvensseihin. Yhdysvaikutusparametri λ_{ij}^{XY} kuvaa muuttujien välistä riippuvuutta.

Taulukko 2.1: Kaksiulotteisissa log-lineaarisissa malleissa esiintyvät parametrit.

Parametri	Tulkinta	Lukumäärä
μ	Tyypillisen solufrekvenssin mitta	1
λ_i^X	Muuttujan X kategorian i päävaikutus	$(I - 1)$
λ_j^Y	Muuttujan Y kategorian j päävaikutus	$(J - 1)$
λ_{ij}^{XY}	Muuttujien X ja Y välinen yhdysvaikutus eli poikkeama riippumattomuudesta solussa (i, j)	$(I - 1)(J - 1)$

[16, s.126]

Havainnot ristiintaulukoidaan kategoristen muuttujien mukaan (esim. sukupuoli), jotka jakautuvat kategorioihin kuten (*mies, nainen*) [5, s.1]. Rajoituksena ristiintaulukoinnissa on siis, etteivät arvot voi olla jatkuvia. Kategoriset muuttujat ovat laadullisia muuttujia, kun taas numeeriset muuttujat, kuten ikä ja tulot, ovat määrellisiä. Kategoriat ovat hyödyllisiä monissa tutkimuksissa esimerkiksi mitatessa mielipidettä, sairauden astetta tai hoidon toimivuutta. [2, s.1-2]

Tarkasteltaessa Poisson-jakautuneen aineiston ristiintaulukkoa, jokainen solu kuvastaa tietyn tapahtuman lukumäärää y_{ij} . Tapahtumat ovat tapahtuneet rajatun

ajanjakson aikana ilman ennakkotietoa havaintojen kokonaismäärästä. [5, s.11]. Ristiintaulukoinnin tarkoitus on kuvata muuttujien välistä riippuvuutta sekä yksinkertaistaa aineiston tulkintaa [8, s.52-53]. Tässä tutkielmassa tarkastellaan miten ristiintaulukoitua frekvenssidataa voidaan mallintaa log-lineaarisilla malleilla.

Aineiston analysoinnissa on huomioitava tulosten luotettavuuteen liittyviä tekijöitä. Esimerkiksi otoskoon kasvaessa alun perin tarkastellut osuudet, joissa esiintyy paljon satunnaisvaihtelua, muuttuvat vähemmän vaihteleviksi. Jokainen osuus suppenee hiljalleen todelliseen raja-arvoonsa eli populaatiotodennäköisyyteen. Tämän vuoksi pienen otoskoon populaatiot eivät ole yhtä luotettavia analysoinnissa. [16, s.5]

2.2 TUTKIMUSAINEISTO

Tutkimusaineisto on peräisin Terveiden ja hyvinvoinnin laitoksen (THL) avoimesta tilastopalvelusta. Aineistoon on koottu frekvenssidataa terveydenhuollon asiakaskäynneistä ja sitä on rajattu useiden muuttujien perusteella. Tässä tutkielmassa muuttujina toimivat hyvinvointialue, palvelusektori, diagnoosi sekä vuosi. Aineiston [14] solut sisältävät lukumäärän eri muuttujien perusteella rajatuista asiakaskäynneistä. Faktorimuuttujat esitetään taulukossa 2.2.

Taulukko 2.2: Analyysissä käytetyt faktorimuuttujat.

Faktori	Lyhenne	Muuttujan tasot
Diagnoosi	D	ICD-10-diagnoosiryhmät (ks. liite B.0.1)
Hyvinvointialue	H	Suomen hyvinvointialueet (ks. liite B.0.2)
Palvelusektori	P	Julkinen, yksityinen, työterveyshuolto
Vuosi	V	2023, 2024, 2025

Aineisto oli alkuperäiseltä rakenteeltaan moniulotteinen taulukko, jonka soluissa esitettiin frekvenssit. Rakennetta jouduttiin muokkaamaan, jotta frekvenssejä voitiin käsitellä analyysin edellyttämällä tavalla. Lisäksi otsikot olivat moniulotteisessa muodossa, mikä vaikeutti niiden lukemista R-ohjelmistolla. Näin ollen dataa oli muokattava ennen varsinaista analyysiä.


Datan siistiminen aloitettiin Excelissä, jossa poistettiin tarpeettomat rivit ja sarakkeet, joita olivat *kaikki sektorit*, *kaikki hyvinvointialueet* sekä *kaikki vuodet*. Tämän lisäksi vuodet eivät olleet erillisenä muuttujana, vaan ne esiintyivät muuttujan arvoina 2023, 2024 ja 2025. Nämä arvot olivat yhtenäisenä levennettynä soluna kaikkien hyvinvointialueiden yllä, minkä seurauksena poistettiin levennys ja kopioitiin vuodet jokaiseen soluun, jotta vuodet eivät näkyisi aineistossa puuttuvina arvoina. Tämän jälkeen aineiston muokkaamista jatkettiin R:ssä.

Aluksi erotettiin otsikkorivit *vuosiluvut* ja *hyvinvointialueet* datasta. Tämän jälkeen luotiin uudet sarakenimet yhdistämällä vuosiluku ja hyvinvointialue yhdeksi arvoksi, kuten *Pirkanmaa_2023*. Sitten poistettiin alkuperäiset otsikkorivit, jolloin jäljelle jäi vain havaintoaineisto. Seuraavassa vaiheessa data muunnettiin niin sanotusta leveästä muodosta pitkään muotoon, jossa solufrekvensseistä muodostettiin

erillinen muuttuja. Aineiston kokonaisfrekvenssi oli $N = 39\,583\,801$.

Tässä vaiheessa jokainen sarake vastasi tiettyä vuoden ja alueen yhdistelmää. Muunnoksessa kaikki sarakkeet yhdistettiin yhdeksi muuttujaksi *Lukumäärä*, ja sarakkeiden nimet pilkottiin kahdeksi muuttujaksi *Vuosi* ja *Hyvinvointialue*. Lopuksi muuttujien tyyppejä muunnettiin analyysiä varten. Lukumäärä-muuttujasta poistettiin mahdolliset välilyönnit ja muut ei-numeeriset merkinnät sekä vuosi-muuttuja muunnettiin kokonaisluvuksi. Tällaisen selkeän taulukon saaminen oli olennainen vaihe tutkimuksessa, sillä ilman sitä aineisto ei olisi ollut yhteensopiva analyysimenetelmien kanssa.

Pylväsdiagrammi 2.1 kuvaa jokaisen diagnoosiryhmän havaintojen lukumäärää. Jokaisen diagnoosin kohdalla on kolme eri väristä pylvästä, joilla esitetään vuotta, jolloin diagnoosit ovat tehty. Kuvaajan perusteella usealla diagnoosiryhmällä havaintoja tehtiin enemmän vuonna 2024 kuin 2023 ja 2025. Ylivoimaisesti eniten havaintoja esiintyy diagnoosikategorioissa *Ruuansulatuselinten sairaudet* ja *Tekijöitä, jotka vaikuttavat terveydentilaan ja yhteydenottoihin terveyspalvelujen tuottajiin*.



Kuva 2.1: Diagnoosiluokkien lukumäärät vuosina 2023-2025.

2.3 KAKSIULOTTEISTEN RISTIINTAULUKOIDEN KHI-NELIÖTESTAUS

Taulukko 2.3 esittää luvussa 2 käsiteltävää dataa, joka on rajattu sisältämään muuttujat *vuosi* ja *palvelusektori*. Aineistossa on lisäksi muuttujat *diagnoosi* ja *hyvinvointialue*, mutta ne eivät ole mukana kaksiulotteisessa tarkastelussa. Molemmat faktorimuuttujat on jaettu kolmeen kategoriaan, jolloin mahdollisia tulosyhdistelmiä on yhdeksän. Taulukon soluissa esitetään näiden tapahtumien lukumäärät eli frekvenssit. Taulukkoa analysoimalla tarkasteltiin, esiintyykö vuoden ja palvelusektorin välillä yhteyttä.

Taulukko 2.3: Palvelusektoreiden frekvenssit vuosina 2023–2025 kaksiulotteisessa ristiintaulukossa.

Sektori	2023	2024	2025
Julkinen	10 828 058	11 277 632	11 078 724
Työterveys	4 853 971	4 991 010	4 829 718
Yksityinen	4 070 173	3 320 721	2 350 627

Pearsonin khi-neliötunnusluku on Karl Pearsonin vuonna 1900 kehittämä testisuure, jota käytetään hypoteesien testaamiseen [1, s.135]. Pearsonin khi-neliötunnusluku nollahypoteesin H_0 testaukselle on

$$X^2 = \sum_{i=1}^n \sum_{j=1}^m \frac{(y_{ij} - \mu_{ij})^2}{\mu_{ij}}, \quad (2.1)$$

missä n ja m ovat ristiintaulukon rivien ja sarakkeiden lukumäärät, y_{ij} havaittu frekvenssi solussa (i, j) ja odotettu frekvenssi $\mu_{ij} = E(y_{ij})$. Kun nollahypoteesina on, että kaksiulotteisen ristiintaulukon solujen todennäköisyydet ovat tietyt kiinteät arvot p_{ij} , saadaan odotetuksi frekvenssiksi $\mu_{ij} = Np_{ij}$, missä N on kokonaisotoskoko.

Satunnaistetuissa kokeissa suurella otoskoolla, X^2 noudattaa suunnilleen χ^2 -jakautumaa. Testin p-arvo kertoo todennäköisyyden sille, että nollahypoteesin vallitessa, X^2 on ainakin yhtäsuuri kuin havaittu arvo. [2, s.36-37]

Ristiintaulukon 2.3 perusteella voidaan tutkia esimerkiksi nollahypoteesin $H_0 : \hat{\mu}_{11} = \hat{\mu}_{12}$ merkitsevyyttä, jolloin selvitetään, onko julkisen terveydenhuollon käyttö säilynyt samalla tasolla peräkkäisinä vuosina. [3, s.24-25]

Tarkastellaan Pearsonin khi-neliötestillä nollahypoteesia H_0 : vuosi ja palvelusektori ovat riippumattomia toisistaan. Testi toteutettiin seuraavalla R-koodilla

```
taulu1 <- xtabs(Lukumäärä ~ Vuosi + Palvelusektori,
data = diagnoosi)

chisq.test(taulu1)
```

Riippumattomuustestin tulokset esitetään taulukossa 2.4, jossa df tarkoittaa vapausasteita. Testin p-arvoksi saatiin $<0,001$, minkä perusteella nollahypoteesi riippumattomuudesta hylätään. Tätä tarkastellaan luvussa 3.3 käsiteltäessä tyyppin I virhettä. Toisaalta aineiston suuri koko voi johtaa siihen, että myös vähäiset poikkeamat näkyvät tilastollisesti merkitsevinä, minkä vuoksi johtopäätöksiä ei voida perustaa pelkkään p-arvoon.

χ^2 -tunnusluvut ovat asymptoottisia tunnuslukuja, jotka approksimoivat χ^2 -jakautumaa, mikäli tietyt oletukset täyttyvät. Nämä oletukset ovat taulukon tapausten riippumattomuus toisistaan, samanlaisen jakauman noudatus sekä otoskoon riittävä suuruus. [17, s.19-21]

Testin perusteella saatu χ^2 -arvo oli erittäin suuri, mikä selittyy aineiston suurilla frekvensseillä, sillä tällöin pienetkin erot korostuvat testisuureessa. Tulos viittasi kuitenkin muuttujien vahvaan riippuvuuteen. Pienen χ^2 -arvon tapauksessa havaittujen ja odotettujen frekvenssien erot olisivat vähäisiä, kuten lausekkeesta 2.1 nähdään. Käytännössä riippumattomuuden vallitessa odotetut frekvenssit ovat likimain yhtä suuria kuin havaitut frekvenssit.

Näiden tulosten perusteella palvelusektorin ja vuoden välillä havaittiin tilastollisesti merkitsevä riippuvuus, mikä viittaa siihen, että palvelusektoreiden jakaumat eroavat vuosien välillä.

Taulukko 2.4: Pearsonin χ^2 -riippumattomuustestin tulokset.

χ^2	279 634
df	4
p-arvo	$<2,2e-16$

Taulukossa 2.3 esiteltiin palvelusektoreiden vuosittain havaitut arvot (engl. observed values). Khi-neliötestissä käytetyt odotusarvon estimaatit esitetään taulukossa 2.5.


Taulukko 2.5: Khi-neliötestin estimoidut arvot.

Sektori	2023	2024	2025
Julkinen	11 379 480	11 285 666	10 519 268
Työterveys	5 032 195	4 990 709	4 651 795
Yksityinen	3 340 527	3 312 988	3 088 006

Havaittujen ja estimoitujen frekvenssien eroja voidaan visualisoida mosaiikkikuvaajalla. Kuvaa 2.2 voidaan tulkita siten, että sininen väri merkitsee havaittujen frekvenssien olevan suurempia kuin riippumattomuusmallin odottamat frekvenssit ja punainen vastaavasti pienempiä. Mitä voimakkaampi väri on, sitä suurempi poikkeama odotetusta frekvenssistä on kyseessä. Kuvaajasta nähdään, että estimoitujen ja havaittujen arvojen välillä on useita suuria poikkeamia, joten hylätään riippumattomuushypoteesi.

Tuloksia voidaan visualisoida myös hajontakuviolla (engl. *scatterplot*). Kuva 2.3 esittää havaittuja ja odotettuja frekvenssejä. Kuvaa voidaan tulkita siten, että suo-

Sektorin ja vuoden riippuvuus



Kuva 2.2: Palvelusektorien käyntimäärän riippuvuus vuodesta esitettynä mosaiikkikuviona.

ralla sijaitsevat pisteet vastaavat tilanteita, joissa havaittu arvo on likimain yhtä suuri kuin odotettu arvo. Suoran yläpuolella olevat pisteet kuvaavat tilanteita, joissa havaintoja on enemmän kuin odotettiin, ja vastaavasti suoran alapuolella olevissa pisteissä havaintoja on vähemmän kuin odotettiin. Arvojen poikkeamat eivät kuitenkaan korostu hajontakuviassa yhtä selvästi kuin kuvaajassa 2.2.


Seuraavaksi tarkastellaan residuaaleja, joiden avulla voidaan havaita, missä kohdissa malli kuvaa aineistoa heikommin. Standardoidut residuaalit noudattavat approksimoidusti standardinormaalijakaumaa $N(0, 1)$ sekä jakavat havaitun ja sovitun frekvenssin erotuksen niiden keskivirheellä, sillä pelkkä erotus voi aiheuttaa harhaanjohtavia tuloksia. Standardointi tekee erikokoisista soluista vertailukelpoisia. [2, s.39, 200]

Pearsonin residuaalit voidaan laskea kaavalla

$$r_{ij} = \frac{y_{ij} - \mu_{ij}}{\sqrt{\mu_{ij}}}, \quad (2.2)$$

missä y_{ij} on havaittu frekvenssi ja μ_i odotettu frekvenssi, kun taas standardoidut residuaalit määritellään kaavalla

$$s_{ij} = \frac{y_{ij} - \mu_{ij}}{\sqrt{\mu_{ij}(1 - \frac{y_{i0}}{y_{00}})(1 - \frac{y_{0j}}{y_{00}})}}. \quad (2.3)$$



Kuva 2.3: Hajontakuvio havaituista ja odotetuista frekvensseistä.

Mikäli muuttujat ovat riippumattomia toisistaan, noin 95% standardoiduista residuaaleista sijoittuu välille $[-2, 2]$. [16, s.44]

Standardoidut residuaalit esitetään yhden desimaalin tarkkuudella taulukossa 2.6. Standardoidut residuaalit olivat suuria lähes kaikissa soluissa, mikä viittaa merkittäviin poikkeamiin havaituista arvoista. Suurimmat poikkeamat havaittiin yksityisen terveydenhuollon sektorilla vuosina 2023 ja 2025. Näiden tulosten perusteella voidaan todeta eri sektorien havaittujen frekvenssien olevan merkittävästi riippuvaisia vuodesta.

Taulukko 2.6: Kaksiulotteisen ristiintaulukon standardoidut residuaalit.

Sektori	2023	2024	2025
Julkinen	-309,7	-4,5	320,6
Työterveys	-113,5	0,2	115,6
Yksityinen	540,3	5,7	-557,0

2.4 KAKSIULOTTEISTEN RISTIINTAULUKOIDEN MALLINNUS

Kaksiulotteiselle ristiintaulukolle riippumaton log-lineaarinen malli on

$$\log(\mu_{ij}) = \lambda + \lambda_i^X + \lambda_j^Y, \quad (2.4)$$

missä yläindeksit X ja Y kuvaavat muuttujia, eivät potensseja. λ on vakiotermi (engl. *intercept*), rivivaikutuksen termi λ_i^X kuvaa rivimuuttujan X tason i vaikutusta ja sarakevaikutuksen termi λ_j^Y sarakemuuttujan Y tason j vaikutusta. Mallia kutsutaan **riippumattomuusmalliksi** (engl. *model of independence*), koska se ei sisällä muuttujien välistä interaktiotermiä. [2, s.193-195]

Riippumaton log-lineaarinen malli koostuu siis pelkistä muuttujista ilman niiden välisiä yhteyksiä. Kun kategoriset muuttujat ovat yhteydessä, saadaan kaksiulotteisen ristiintaulukon tilanteessa malli

$$\log(\mu_{ij}) = \lambda + \lambda_i^X + \lambda_j^Y + \lambda_{ij}^{XY}, \quad (2.5)$$

missä uusi parametri λ_{ij}^{XY} on **assosiaatiotermi** eli sillä kuvataan muuttujien X ja Y välistä interaktiota [2, s.196].

Aineistoon sovitettiin sekä riippumaton että assosiaatiotermiä sisältävä log-lineaarinen malli, minkä jälkeen malleja verrattiin keskenään ANOVA-testillä. Kaksiulotteisessa mallinnuksessa tarkasteltiin muuttujia *vuosi* ja *palvelusektori*. Vertailu toteutettiin R-ohjelmistossa koodilla

```
# Riippumaton malli
malli1 <- glm(Lukumäärä ~ Vuosi + Palvelusektori, family =
poisson, data = diagnoosi)

# Assosiaatiotermi mukana
malli2 <- glm(Lukumäärä ~ Vuosi * Palvelusektori, family =
poisson, data = diagnoosi)

anova(malli1, malli2, test = "Chisq")
```

Log-lineaarisessa analyysissä valitaan malli, joka kuvaa aineistoa parhaiten mahdollisimman yksinkertaisella rakenteella. Sopivin malli on se, jolla residuaalidevianssi on pienin, kun huomioidaan mallin rakenteellinen tulkittavuus. [4]

Taulukossa 2.7 esiintyvien tulosten perusteella devianssi on tilastollisesti merkitsevästi pienempi assosiaatiotermiä sisältävässä mallissa, minkä perusteella voidaan todeta sen kuvaavan aineistoa paremmin kuin riippumattomuusmalli. Täten jatkotarkasteluun valittiin assosiaation sisältävä malli (malli 2).

Taulukko 2.7: Kaksiulotteisen mallin ANOVA-testin tulokset.

	df	D	P-arvo
Malli 1	4797	63 969 724	
Malli 2	4793	63 705 919	< 0,001

Mallin antamat estimaatit, keskivirheet ja z-arvot esitetään taulukossa 2.8 kahden desimaalin tarkkuudella. Valittu malli on aineiston tapauksessa muotoa

$$\log(\mu_{ij}) = \lambda + \lambda_i^V + \lambda_j^P + \lambda_{ij}^{VP}. \quad (2.6)$$

Hajontapametrillä ϕ tarkoitetaan devianssin ja vapausasteiden suhdetta. Ihan-teellisessa Poisson-mallissa $\phi \approx 1$. Mikäli $\phi > 1$, havaitaan **yliahajontaa**. [6, s.396] Tässä aineistossa havaittiin voimakasta yliahajontaa sekä riippumattomuus- että assosiaatiomallissa. Hajontaparametrin arvoksi saatiin n. 13 000, mikä osoittaa, että mallit ovat aineistoon nähden liian yksinkertaisia.

Yliahajontaa voidaan käsitellä kvasiuskottavuuteen (engl. *quasi-likelihood*) perustu-villa Poisson-jakauman kaltaisilla oletuksilla, kuten kvasi-Poisson-mallilla. Toinen vaihtoehto yliahajonnan tapauksessa on soveltaa negatiivista binomijakaumaa. [7, s.2766] Yliahajonnasta huolimatta tämän tutkielman mallit antavat hyödyllisen ra-kenteellisen kuvauksen muuttujien välisistä riippuvuuksista, ja tulokset tulkitaan yliahajonta huomioiden.

Taulukossa 2.8 vakio-termi (engl. *intercept*) kuvaa viitetason logaritmoitua odo-tettua frekvenssiä $\log(\mu)$. Tässä viitesoluna toimii vuosi 2023 ja julkinen palve-lusektori. Tällöin $\exp(\lambda)$ on sen solun odotettu frekvenssi, jossa kaikki kategoriset muuttujat ovat viitetasoillaan. Koska malli esitetään logaritmisessa muodossa, parametrien eksponentit kuvaavat suhteellisia muutoksia odotetuissa frekvens-seissä tai solutodennäköisyyksissä verrattuna viitetasoon. [15, s.212]

Positiivinen kerroin tarkoittaa, että vastaavassa kategoriassa odotettu frekvenssi on suurempi kuin viitetasossa, kun taas negatiivinen kerroin tarkoittaa pienempää odotettua frekvenssiä. Koska malli on logaritminen, vaikutukset ovat suhteellisia.

Tarkastellaan esimerkiksi vuoden 2024 estimaattia 0,048. Tällöin $\exp(0,048) \approx 1,049$ eli vuoden 2024 odotettu frekvenssi on noin 4,9% suurempi kuin vuonna 2023 eli viitetasossa, kun sektori pidetään vakiona. Toisena esimerkkinä yksityi-sellä sektorilla odotettu frekvenssi on $\exp(-1,06) \approx 0,35$ mukaisesti 65% pienem-pi kuin julkisella sektorilla, kun vuosi on vakio. Parametrien tulkintaan palataan myöhemmin estimointiteoriaa käsitellessä lausekkeessa 3.10.

Keskivirhe kuvaa estimaatin epävarmuutta: mitä pienempi keskivirhe, sitä tarkem-pi estimaatti on. Z-arvo saadaan estimaatin ja sen keskivirheen suhteena, ja sen perusteella arvioidaan parametrin tilastollista merkitsevyyttä. Kaikkien paramet-rien p-arvoiksi saatiin $<0,001$, mikä viittaa siihen, että jokaisella parametrillä on yhteys odotettuun frekvenssiin.


Tutkitaan assosiaatiomallin odotusarvoja ja verrataan niitä havaittuihin arvoihin. Kuvaajasta 2.4 nähdään, että havaitut arvot poikkeavat selvästi mallin estimois-mista arvoista, sillä havainnot eivät sijoitu suoralle. Täydellisessä mallissa arvot ovat yhtä suuret eli pisteet sijoittuvat suoralle. Pylväsmäinen rakenne johtuu siitä, että useat havainnot kuuluvat samaan vuoden ja sektorin yhdistelmään ja saavat siten saman estimoidun arvon. Havaittujen ja estimoitujen arvojen selkeät poikkemat viittaavat siihen, ettei malli kuvaa aineistoa riittävän hyvin.

Valitun log-lineaarisen mallin sopivuutta aineistoon arvioitiin lisäksi residuaalitut-kinnan avulla taulukossa 2.9. Tarkastelussa käytettiin Pearson-, devianssi- ja stan-dardoituja residuaaleja. Residuaalit on esitetty yhdessä niitä vastaavien solujen indeksien kanssa. Tulosten tarkastelua varten taulukkoon on valittu viisi itseisar-voltaan suurinta residuaalia, jotka kuvaavat mallin suurimpia poikkeamia havai-tuista frekvensseistä.

Taulukko 2.8: Sovitetun kaksikulotteisen log-lineaarisen mallin tulokset.

	$\hat{\beta}$	S.E. ($\hat{\beta}$)	z
Vakiotermi	9,52	0,00037	26046,26
2024	0,048	0,00051	94,29
2025	0,038	0,00051	75,10
Työterveyshuolto	-0,74	0,00065	-1132,82
Yksityinen terveydenhuolto	-1,06	0,00073	-1457,88
2024Työterveys	-0,016	0,00091	-17,36
2025Työterveys	-0,033	0,00092	-35,65
2024Yksityinen	-0,26	0,0011	-239,38
2025Yksityinen	-0,58	0,0012	-497,98

Kaksikulotteisen mallin havaittujen ja estimoitujen frekvenssien vertailu

**Kuva 2.4:** Hajontakuvio havaituista ja estimoiduista frekvensseistä valitussa kaksikulotteisessa log-lineaarisessa mallissa.

Taulukon 2.9 indeksejä avataan taulukossa 2.10. Itseisarvoltaan suurimmat residuaalit ovat erittäin suuria, mikä viittaa siihen, että mallin sopivuus ei ole kyseisissä soluissa hyvä. Suurimmat residuaalit esiintyvät Helsingin alueen julkisessa terveydenhuollossa. Nämä solut saattavat poiketa mallin yleisestä rakenteesta tai kertoa mallin huonosta sopivuudesta aineistoon. Tätä voidaan tarkastella residuaalikuvaajan avulla. Suurimmat residuaalit esiintyvät Helsingin alueen julkisessa terveydenhuollossa.

Taulukko 2.9: Viisi itseisarvoltaan suurinta valitun mallin residuaalia.

	Pearson	devianssi	standardi
1.	[4530] 1436,64	[4530] 782,50	[4530] 1437,95
2.	[4505] 1374,39	[4555] 753,065	[4505] 1375,65
3.	[4555] 1364,92	[4505] 752,82	[4555] 1366,17
4.	[2280] 1184,25	[2280] 679,97	[2280] 1185,34
5.	[2255] 1167,62	[2255] 668,65	[2255] 1168,69

Taulukko 2.10: Suurimpia residuaaleja vastaavat havaintoyhdistelmät. Mallin selittäviä muuttujia olivat sektori ja vuosi, mutta taulukossa esitetyt havainnot on indeksoitu usean luokittelumuuttujan (diagnoosi, palvelusektori, vuosi, hyvinvointialue) mukaan.

Indeksi	Diagnoosi	Sektori	Vuosi	Alue
4530	Z00-ZZB	Julkinen	2024	Helsinki
4505	Z00-ZZB	Julkinen	2023	Helsinki
4555	Z00-ZZB	Julkinen	2025	Helsinki
2280	K00-K93	Julkinen	2024	Helsinki
2255	K00-K93	Julkinen	2023	Helsinki


Mallin sopivuutta voidaan tarkastella myös residuaalikuvaajalla. Hyvin sopivassa mallissa pisteet sijoittuvat satunnaisesti hajalleen koko alueelle ilman havaittavaa trendiä. Huonossa mallissa puolestaan esiintyy viuhkamaista rakennetta, kasvavaa hajontaa, trendiä tai ryhmittäytymistä. Huonon sopivuuden lisäksi nämä piirteet saattavat viitata ylihajontaan. [4]

Kuvaajassa 2.5 esitetään mallin Pearson-residuaalit y-akselilla ja mallin sovitettut arvot x-akselilla. Kuvaajassa näkyy selkeää ryhmittymistä pylväisiin, kuten kuvaajassa 2.4 aiemmin. Lisäksi kasvava hajonta ja pisteiden sijainti viittaa siihen, että mallin sopivuus aineistoon on heikko. Voidaan siis todeta, että suurimmat residuaalit eivät olleet poikkeavia soluja, vaan epäsopevuus koskee koko aineistoa.

Residuaalitutkimuksen tulokset viittaavat siihen, että mallista puuttuu jokin aineiston rakennetta selittävä tekijä, jonka vuoksi mallin odotetut frekvenssit poikkeavat selvästi havaituista arvoista.

Kaksiulotteinen tarkastelu voi johtaa harhaan, jos taustalla vaikuttaa muita muuttujia. Tällöin kahden muuttujan välinen yhteys voi muuttua, kun analyysiin lisätään kolmas muuttuja. Tätä ilmiötä kutsutaan Simpsonin paradoksiksi. [16, s.141-143]

Esimerkiksi tutkielman datassa vuosi–palvelusektori-yhteys voi muuttua, kun tarkastelu tehdään diagnoosiryhmittäin. Tällöin voidaan havaita, että yksityisen sektorin käyntimäärät kasvoivat vuosien 2023-2025 välillä enemmän kuin julkisella sektorilla aggregoidussa aineistossa, mutta diagnoosikohtaisesti tarkasteltuna kasvu ei välttämättä ole yhtenäinen kaikissa ryhmissä, ja joissakin tapauksissa kasvu voi olla suurempaa julkisella sektorilla.



Kuva 2.5: Pearsonin residuaalit kaksiulotteisen mallin sovituksen arvioimiseksi.

3 LOG-LINEAARISEN MALLIN TEORIAA

3.1 POISSON-JAKAUMA JA LOG-LINKKIFUNKTIO

Poissonin log-lineaariset mallit kuuluvat yleistettyihin lineaarisiin malleihin (engl. *generalized linear models*). Ne huomioivat solufrekvenssit riippumattomina havaintoina sekä noudattavat Poisson-jakaumaa. Yleistetyillä lineaarisilla malleilla voidaan tarkastella muuttujien yhteyksiä, kun selitettävät muuttujat eivät noudata normaalijakaumaa tai ole jatkuvia. Tällaiset mallit koostuvat satunnaisosasta, joka määrittelee havaintojen jakauman, lineaarisesta ennusteesta (engl. *linear predictor*) ja linkkifunktiosta. [1, s.2]

Mallin estimoitu arvo perustuu lineaariseen ennusteseen η , joka voidaan esittää

$$\eta_i = \sum_{j=1}^p x_{ij}\beta_j, \quad (3.1)$$

missä x_{ij} ovat selittävien muuttujien arvoja ja β_j ovat mallin parametrejä. Lineaarinen ennuste muunnetaan linkkifunktion avulla odotusarvoksi $g(\mu) = \eta$. [4] Linkkifunktiolla g tarkoitetaan funktiota, joka lisätään jokaiseen y_i :n odotusarvon komponenttiin liittäen sen lineaariseen ennusteeseen. Log-lineaarisisissa malleissa käytetään log-linkkifunktiota

$$g[E(y_i)] = g(\mu_i) = \log(\mu_i). \quad (3.2)$$

[1, s.2] Täten estimoiduksi odotusarvoksi saadaan $\mu_i = \exp(\eta_i)$ [4].

Log-lineaarisia malleja käytetään frekvenssiaineiston solulukumäärien mallintamiseen kategoristen muuttujien suhteen [2, s.193]. Koska solufrekvenssit ovat epänegatiivisia kokonaislukuja, niitä mallinnetaan yleensä Poisson-jakauman avulla [1, s.5]. Mallin parametrien avulla voidaan kuvata kategoristen muuttujien välisiä assosiaatiota [2, s.193].

Poisson-jakaumalla kuvataan usein sellaisia tapahtumia, jotka tapahtuvat satunnaisesti tietyssä ajassa tai paikassa tietyllä nopeudella, kun erillisten ajanjaksojen tai paikkojen tapahtumat ovat riippumattomia [1, s.229]. Esimerkiksi tässä tutkielmassa sillä voidaan kuvata, kuinka moni potilas Ahvenanmaan hyvinvointialueella on diagnosoitu tartunta- ja loistauteihin tai kuinka moni Suomen kasvaindiagnooseista on tehty yksityisellä palvelusektorilla vuonna 2023.

Poisson-jakaumalle on olennaista, että todennäköisyydet riippuvat vain yhdestä parametrystä, odotusarvosta μ_i , sillä $\text{var}(y_i) = E(y_i) = \mu_i$. Poisson-jakauman pistemassafunktio on

$$p(y_i; \mu_i) = \frac{e^{-\mu_i} \mu_i^{y_i}}{y_i!}. \quad (3.3)$$

Funktio voidaan muokata eksponenttimuotoon, ja näin osoittaa sen kuuluvan eksponenttijakaumaperheeseen eli yleistettyjen lineaaristen mallien yhteiseen jakaumaperheeseen. [1, s.229] Tämä on esitetty lausekkeessa 3.6.

Poisson-jakauma on yksihuppuinen ja sen vinoutta voidaan kuvata kertoimella

$$\frac{E(y_i - \mu_i)^3}{\sigma_i^3} = \frac{1}{\sqrt{\mu_i}}, \quad (3.4)$$

joten odotusarvon μ_i kasvaessa jakauman vinous pienenee ja jakauma lähestyy normaalijakaumaa [1, s.229].

Poisson-jakautuneen vastemuuttujan y_i odotusarvo on usein verrannollinen indeksiin t_i , joka voi kuvata esimerkiksi aikaa tai populaation kokoa. Tällöin tarkastellaan suhteellista tapahtumatiheyttä y_i/t_i , jonka odotusarvo on μ_i/t_i . Tälle odotusarvolle log-lineaarinen malli voidaan kirjoittaa muodossa

$$\log(\mu_i/t_i) = \sum_{j=1}^p \beta_j x_{ij}. \quad (3.5)$$

Logaritmin laskusääntöjen perusteella $\log(\frac{\mu_i}{t_i}) = \log(\mu_i) - \log(t_i)$. Tällöin termiä $\log(t_i)$ kutsutaan **offset**-termiksi. [1, s.233]

Poisson-jakauman yksi ominaisuus on varianssin ja odotusarvon yhtäsuuruus. Ylihajonnan (engl. *overdispersion*) tapauksessa lukumäärämuuttujat vaihtelevat enemmän kuin Poisson-malli ennustaa. Täten siis varianssi on suurempaa kuin odotusarvo. Ylihajonnan syynä on tyypillisesti heterogeenisyys eli tilanne, jossa selittävät muuttujat pidetään vakiona, mutta vasteen odotusarvo vaihtelee tuntemattomien tekijöiden vuoksi. Ylihajonta tuottaa viallisen mallin varianssin kannalta, mikä voi johtaa väärin päätelmiin. [1, s.231-232] Lisäksi ylihajontaa voi aiheuttaa havaintojen klusteroituminen [12, s.183].

3.2 ESTIMOINTITEORIAA

Havaintojen y_i noudattaessa Poisson-jakaumaa, voidaan todennäköisyysmassafunktio muokata eksponenttijakaumaperheen muotoon

$$\begin{aligned} f(y_i; \mu_i) &= \frac{e^{-\mu_i} \mu_i^{y_i}}{y_i!} \\ &= \exp\left(\frac{y_i \log(\mu_i) - e^{\log(\mu_i)}}{1} - \log(y_i!)\right) \\ &= \exp\left(\frac{y_i \theta_i - e^{\theta_i}}{1} - \log(y_i!)\right), \quad y_i = 0, 1, 2, 3, \dots, \end{aligned} \quad (3.6)$$

missä $\theta_i = \log(\mu_i)$ on luonnollinen parametri. [1, s.122] Luonnollinen parametri on yleistetyissä lineaarisissa malleissa odotusarvon funktio, joka on ominainen jokaiselle satunnaismuuttujan y_i jakaumalle [2, s.67].

Määritellään todennäköisyysmassafunktion perusteella uskottavuusfunktio

$$L(y_i; \mu_i) = \prod_{i=1}^n \frac{e^{-\mu_i} \mu_i^{y_i}}{y_i!} \quad (3.7)$$

ja log-uskottavuusfunktio

$$\ell(y_i; \mu_i) = -n\mu_i + \sum y_i \log(\mu_i) - \sum \log(y_i!) . \quad (3.8)$$

Koska $\text{var}(y_i) = \mu_i$, uskottavuusyhtälöt suurimman uskottavuuden estimaattorille $\hat{\beta}$ sievenee muotoon

$$\begin{aligned} \frac{\partial l(\beta)}{\partial \beta_j} &= \sum_{i=1}^n \frac{(y_i - \mu_i)x_{ij}}{\text{var}(y_i)} \frac{\partial \mu_i}{\partial \eta_i} = \sum_{i=1}^n \frac{(y_i - \mu_i)x_{ij}}{\mu_i} \frac{\partial \mu_i}{\partial \eta_i} \\ &= \sum_{i=1}^n (y_i - \mu_i)x_{ij} = 0, \quad j = 1, 2, \dots, p, \end{aligned} \quad (3.9)$$

missä $\eta_i = \sum_{j=1}^p \beta_j x_{ij} = g(\mu_i)$. Nämä uskottavuusyhtälöt saavat β :n tyhjentävät tunnusluvut $\sum_i y_i x_{ij}$ yhtäsuuriksi odotusarvojen kanssa. [1, s.124-125]

Uskottavuusyhtälöiden avulla estimoidaan regressiomallin parametrit minimomallilla testisuuretta, joka mittaa mallin poikkeamaa täydellisestä regressiomallista eli mallista, jossa estimoidut arvot vastaavat täsmälleen havaittuja arvoja. Huonosti aineistoon sopivien mallien devianssi on suuri, koska estimoidut arvot poikkeavat selvästi havaituista arvoista. [6, s.396-397]

Mitä suurempi erotus $y_i - \mu_i$ on, sitä huonommin malli kuvaa havaintoja ja sitä suurempi devianssi on. Kun malliin lisätään parametrejä, se pystyy kuvaamaan aineiston vaihtelua paremmin, jolloin estimaatit lähenevät havaittuja arvoja ja devianssi pienenee. [6, s.396-397]

Uskottavuusyhtälöt riippuvat havaintojen y_i jakaumasta vain odotusarvon μ_i ja varianssin $\text{var}(y_i)$ kautta. Varianssi puolestaan on riippuvainen odotusarvosta funktionaalisen muodon $\text{var}(y_i) = v(\mu_i)$ kautta, jollekin funktiolle v . Poisson-jakauman tapauksessa $v(\mu_i) = \mu_i$. [1, s.125]

Havaintojen odotusarvo toteuttaa eksponentiaalisen suhteen

$$\mu_i = \exp\left(\sum_{j=1}^p \beta_j x_{ij}\right) = (e^{\beta_1})^{x_{i1}} \dots (e^{\beta_p})^{x_{ip}}, \quad (3.10)$$

eli odotusarvo muuttuu eksponentiaalisesti kategoristen muuttujien funktioina. Kun x_{ij} kasvaa yhdellä yksiköllä $x_{ij} + 1$, sen odotusarvo on yhtäsuuri kuin x_{ij} :n kerrottuna e^{β_j} :lla, kun muut selittävät muuttujat pidetään vakioina. [1, s.230]

Parametrien estimoinnin lisäksi on tärkeää tarkastella estimaattien vaihtelua ja epävarmuutta. Tätä varten hyödynnetään estimaattien kovarianssimatriisia, joka saadaan informaatiomatriisin avulla.

Kovarianssimatriisi on informaatiomatriisin $\mathcal{J}$ käänteismatriisi. Informaatiomatriisi on mallimatriisin X avulla kuvattuna $\mathcal{J} = X^T W X$. Tällöin estimoitu kovarianssimatriisi $\hat{\beta}$:lle on

$$\widehat{\text{var}}(\hat{\beta}) = (X^T \hat{W} X)^{-1}, \quad (3.11)$$

missä W on diagonaalimatriisi, joka koostuu alkioista $w_i = (\partial \mu_i / \partial \eta_i)^2 / \text{var}(y_i) = \mu_i$.

Näin ollen $\hat{\beta}$:n asympotoottiseksi jakaumaksi saadaan $\hat{\beta} \sim N(\beta, (X^T \hat{W} X)^{-1})$. Asympotoottista normaalisuutta hyödynnetään esimerkiksi parametrien keskivirheiden, luottamusvälien ja tilastollisten testien muodostamisessa. [1, s.126, 231]

3.3 MALLIN SOVITUS

Malleja sovittaessa pyritään selvittämään, mikä malli kuvastaa havaintoaineistoa parhaiten eli mikä malli antaa parhaan sovituksen (engl. *fit*). Tämä tehdään estimoimalla odotettuja solufrekvenssejä μ_i ja vertailemalla niitä havaittuihin solufrekvensseihin y_i . Vertailu voidaan tehdä esimerkiksi Pearsonin khi-neliötestisuureen X^2 tai uskottavuussuhdetestisuureen G^2 avulla. Mitä pienempi poikkema havaittujen ja estimoitujen frekvenssien välillä on, sitä paremmin malli soveltuu aineistoon. [9, s.30]

Testitulosten perusteella malli voidaan hylätä, hyväksyä riittävän hyväksi tai jatkaa sen muokkaamista. Vertailussa käytettäviä testisuureita kutsutaan yhteensopivuustestisuureiksi (engl. *goodness of fit*), sillä ne kuvaavat havaittujen ja mallin estimoitujen jakaumien välistä eroa. [17, s.29]

Merkitsevyystestillä (engl. *significance test*) arvioidaan, kuinka todennäköistä olisi saada vähintään yhtä suuri poikkeama havaittujen ja estimoitujen frekvenssien välillä, jos nollahypoteesi olisi tosi. Tätä todennäköisyyttä kutsutaan p-arvoksi. Pieni p-arvo (<0.05) viittaa siihen, ettei satunnaisvaihtelu yksinään riitä selittämään havaittuja poikkeamia. [17, s.29]

Yleisesti uskottavuussuhdetestisuuretta G^2 pidetään suotavampana kuin Pearsonin khi-neliötestisuuretta X^2 , koska odotetut frekvenssit estimoidaan suurimman uskottavuuden menetelmällä. Lisäksi G^2 voidaan jakaa yksikäsitteisesti osiin, mikä mahdollistaa tehokkaammat testit ehdolliselle riippumattomuudelle moniulotteisissa frekvenssitaulukoissa. [9, s.30]

Testisuure G^2 noudattaa approksimatiivisesti χ^2 -jakaumaa. Mitä suurempi G^2 on suhteessa vapausasteisiin, sitä suurempi poikkeama havaittujen ja odotettujen frekvenssien välillä on. Tällöin poikkeamia ei voida selittää pelkällä satunnaisvaihtelulla, joten nollahypoteesi hylätään. [9, s.30]

Sopivan log-lineaarisen mallin estimoitujen solufrekvenssien ei tulisi poiketa merkittävästi havaituista frekvensseistä. Hypoteesitestissä valitaan etukäteen merkitsevyystaso α , joka vastaa tyypin I virheen todennäköisyyttä. Tyypin I virhe tarkoittaa tilannetta, jossa tosi nollahypoteesi hylätään virheellisesti. Tyypillisesti merkitsevyystasoksi valitaan esimerkiksi $\alpha = 0.05$ tai 0.01 , jolloin riski tehdä tyypin I virhe on 5% tai 1%. [9, s.31]

Tyypin II virhe eli β tapahtuu, kun virheellistä nollahypoteesia ei hylätä. Tällöin aineistossa olevia todellisia riippuvuuksia tai poikkeamia ei havaita, vaan niiden oletetaan johtuvan satunnaisvaihtelusta. Tyypin II virheen todennäköisyyttä voidaan pienentää kasvattamalla otoskokoa tai käyttämällä suurempaa merkitsevyystasoa, mikä samalla kasvattaa tyypin I virheen riskiä. [9, s.31]

Uskottavuussuhdetesti (engl. *likelihood ratio test*) vertailee kahden sisäkkäisen mallin maksimoituja log-uskottavuusfunktioita. Näistä malleista laajempaa kut-

sutaan täydeksi malliksi ja suppeampaa rajoitetuksi malliksi (engl. *reduced model*). Rajoitettu malli muodostetaan asettamalla täydelle mallille nollahypoteesin mukaisia rajoitteita. [18, s.279]

Uskottavuussuhdetestin testisuure määritellään muodossa $LRT = -2(\hat{L}_{raj} - \hat{L}_{täy})$, missä $\hat{L}_{raj}$ ja $\hat{L}_{täy}$ ovat rajoitetun ja täyden mallin maksimoidut log-uskottavuudet. Nollahypoteesin vallitessa testisuure noudattaa approksimatiivisesti χ^2 -jakaumaa, jonka vapausasteet ovat verrattavien mallien vapausasteiden erotus. [18, s.199, 279]

Log-lineaaristen mallien yhteydessä uskottavuussuhdetestin testisuurena käytetään suuretta

$$G^2 = 2 \sum y_i \log\left(\frac{y_i}{\mu_i}\right), \quad (3.12)$$

missä y_i on havaitut frekvenssit ja μ_i mallin estimoidut odotetut frekvenssit. Testisuure G^2 noudattaa likimain χ^2 -jakaumaa. [9, s.30]

Devianssia voidaan käyttää mallin sopivuuden arviointiin. Devianssi noudattaa approksimatiivisesti χ^2 -jakaumaa, jossa vapausasteet ovat solujen lukumäärän ja mallin parametrien lukumäärän erotus. [2, s.200]

Poisson-jakauman tapauksessa devianssi $D(y, \mu)$ voidaan merkitä yhtä suureksi kuin G^2 , sillä $\mu_i = \sum y_i$. Tällöin devianssin lauseke

$$D(y_i, \mu_i) = 2 \sum_{i=1}^n (y_i \log\left(\frac{y_i}{\mu_i}\right) - y_i + \mu_i) \quad (3.13)$$

sievenee muotoon

$$D(y_i, \mu_i) = 2 \sum_i (y_i \log\left(\frac{y_i}{\mu_i}\right)), \quad (3.14)$$

joka vastaa uskottavuussuhdetestisuureen G^2 kaavaa (3.12). [1, s.231]

Yhteensopivuustestisuureet G^2 ja X^2 antavat kuitenkin vain yleisen arvion mallin sopivuudesta ja mahdollisesta epäsojivuudesta (engl. *lack of fit*). Soluresiduaalit puolestaan kuvaavat sovituksen laatua yksittäisten solujen tasolla. Niiden avulla voidaan tunnistaa, mitkä solut poikkeavat eniten mallin ennustamista arvoista ja mahdollisesti aiheuttavat epäsojivuutta, vaikka malli kokonaisuutena näyttäisi sopivalta aineistoon. [2, s.201]

Devianssiresiduaalit ovat vaihtoehtoisia mittareita mallin sopivuudelle, ja ne jakaavat devianssin solukohtaisiin osiin. Pearsonin residuaalin nimittäjä huomioi havaittujen arvojen y_i vaihtelun, mutta ei ota suoraan huomioon estimoitujen odotusarvojen μ_i epävarmuutta. Standardoidut residuaalit sen sijaan huomioivat sekä havaintojen että estimoitujen arvojen vaihtelua, minkä vuoksi niitä pidetään usein Pearsonin ja devianssiresiduaalien täydennyksenä ja tulkinnallisesti käyttökelpoisempina. [2, s.81]

4 MONIULOTTEINEN LOG-LINEAARINEN ANALYYSI

4.1 KOLMIULOTTEISTEN RISTIINTAULUKOIDEN MALLINNUS

Tässä luvussa tarkastellaan log-lineaaristen mallien redusoituja muotoja moniulotteisissa ristiintaulukoissa, ja sovitetaan näitä tutkimusaineistoon.

Erilaisia redusoituja malleja ovat muun muassa riippumaton malli, homogeeninen malli, yhteisesti riippumaton (engl. *joint independence*) ja ehdollisesti riippumaton malli (engl. *conditional independence*) [13, s.4].

Kolmiulotteisessa ristiintaulukossa riippumattomuusmalli voidaan määritellä kuten kaksiulotteisessa taulukossa, kun kaikkien muuttujien oletetaan olevan toisistaan riippumattomia. Jos taas kaksi muuttujista ovat toisistaan riippuvia, mutta molemmat ovat riippumattomia kolmannesta muuttujasta, kyseessä on **yhteisesti riippumaton malli**

$$\log(\mu_{ijk}) = \lambda + \lambda_i^X + \lambda_j^Y + \lambda_k^Z + \lambda_{ij}^{XY}. \quad (4.1)$$

[13, s.4] Tutkimusaineiston tapauksessa yhteisesti riippumattomassa mallissa vuosi voi olla yhteydessä palvelusektoriin, mutta kumpikaan näistä muuttujista ei ole riippuvainen diagnoosista. Tällöin diagnoosin jakauma ei riipu kummastakaan muuttujasta.

Kolmen muuttujan **homogeeninen malli** voidaan esittää muodossa

$$\log(\mu_{ijk}) = \lambda + \lambda_i^X + \lambda_j^Y + \lambda_k^Z + \lambda_{ij}^{XY} + \lambda_{ik}^{XZ} + \lambda_{jk}^{YZ}. \quad (4.2)$$

Käytännössä tämä tarkoittaa, että mikä tahansa kahden muuttujan välinen vetosuhte (engl. *odds ratio*), joka on muodostettu muuttujien X ja Y perusteella, on sama kaikilla Z :n kategorioilla. [2, s.56] Homogeeninen assosiaatio tarkoittaa, että kaikkien muuttujaparien väliset yhteydet ovat samat kolmannen muuttujan eri tasolla. Tämä vastaa tilannetta, jossa mallissa ei ole mukana kolmen muuttujan välistä interaktiotermiä λ_{ijk}^{XYZ} . [2, s.198].

Ehdollisen riippumattomuuden malli tarkoittaa kolmen muuttujan tapauksessa tilannetta, jossa kaksi muuttujista ovat ehdollisesti riippumattomia kolmannen muuttujan suhteen. Tällöin mallissa ei esiinny assosiaatiotermiä, joka kuvaa näiden kahden muuttujan välistä yhteyttä. Malli voidaan esittää seuraavasti

$$\log(\mu_{ijk}) = \lambda + \lambda_i^X + \lambda_j^Y + \lambda_k^Z + \lambda_{ij}^{XY} + \lambda_{ik}^{XZ}, \quad (4.3)$$

missä muuttujien Y ja Z välinen assosiaatio on poistettu mallista eli $\lambda_{jk}^{YZ} = \lambda_{ijk}^{XYZ} = 0$. [13, s.4]

Poissonin log-lineaarinen kolmen muuttujan **saturoitu malli** on muotoa

$$\log(\mu_{ijk}) = \lambda + \lambda_i^X + \lambda_j^Y + \lambda_k^Z + \lambda_{ij}^{XY} + \lambda_{ik}^{XZ} + \lambda_{jk}^{YZ} + \lambda_{ijk}^{XYZ}. \quad (4.4)$$

Saturoitu malli sisältää vakion, päävaikutukset, kahden muuttujan väliset vuorovaikutukset sekä kolmen muuttujan yhteisvaikutuksen. Malli kuvaa täydellistä riippuvuutta. [2, s.197]

Kolmiulotteisessa mallinnuksessa muuttujina oli diagnoosi, vuosi ja palvelusektori. Tarkoituksena oli selvittää, millaisia riippuvuusrakenteita muuttujien välillä esiintyy. Mallinnuksen tulokset esitetään taulukossa 4.1.

Yhden interaktion sisältäviä malleja verrattiin riippumattomuusmalliin, kun taas kaikki kaksisuuntaiset interaktiot sisältävää mallia verrattiin täyteen malliin. Tuloksista saatu devianssi toimii uskottavuussuhdetestisuurena hypoteesille, jonka mukaan ne kaikki saturoidun mallin parametrit, jotka eivät sisälly tarkasteltavaan malliin, ovat 0.

Pienimmät yhteensopivuustestisuureet oli malleilla $[DP][V]$, $[VP][DP]$, $[DP][DV]$, $[DP][DV]$, $[DV][DP][PV]$ ja $[DPV]$. Yhteisesti riippumaton ja ehdollisen riippumattomuuden mallit ovat liian yksinkertaisia kuvaamaan aineistoa, joten jäljelle jää homogeeninen ja täysi malli. Täyden mallin ja homogeenisen mallin devianssien erotus on $28305605 - 28262525 = 43080$, ja vastaava vapausasteiden erotus on $4712 - 4670 = 42$. Erotus on tilastollisesti merkitsevä. Aineiston erittäin suuren koon vuoksi kuitenkin myös pienet poikkeamat johtavat helposti merkitseviin testituloksiin, jolloin pelkkä p-arvo ei riitä mallin sopivuuden arviointiin.

Taulukko 4.1: Log-lineaaristen mallien vertailu kolmen muuttujan tapauksessa.

Malli	G^2	X^2	Vapausasteet
$[D][P][V]$	34 781 836	45 141 699	4777
$[VP][D]$	34 503 991	44 389 287	4775
$[DP][V]$	28 755 429	33 424 089	4735
$[DV][P]$	34 592 649	44 459 902	4756
$[VP][DP]$	28 477 380	32 834 600	4733
$[VP][VD]$	34 314 956	43 769 841	4754
$[DP][DV]$	28 567 154	33 083 343	4714
$[DV][DP][PV]$	28 305 605	32 538 940	4712
$[DPV]$	28 262 525	32 460 351	4670

On kuitenkin huomattavaa, että yhteisesti riippumaton malli $[DP][V]$ ja ehdollisesti riippumattomat mallit $[VP][DP]$ ja $[DP][DV]$ alentavat devianssia lähes yhtä paljon kuin homogeeninen malli. Tämä viittaa siihen, että diagnoosin ja palvelusektorin välinen riippuvuus selittää suuren osan aineiston riippuvuusrakenteesta.


Mallivertailujen perusteella kaikkien kaksisuuntaisten interaktioiden sisältämä eli homogeeninen malli $[DV][DP][PV]$ kuvaa aineistoa parhaiten. Vaikka täysi malli $[DPV]$ parantaa sovitusta, parannus on suhteellisen pieni verrattuna parametrien

määrän kasvuun. Tämän vuoksi mallia $[DV][DP][PV]$ voidaan pitää aineiston kanalta riittävänä mallina. Malli voidaan esittää

$$\log(\hat{\mu}_{ijk}) = \lambda + \lambda_i^D + \lambda_j^P + \lambda_k^V + \lambda_{ij}^{DP} + \lambda_{ik}^{DV} + \lambda_{jk}^{PV}. \quad (4.5)$$

Valitussa mallissa esiintyy edelleen voimakasta ylihajontaa, sillä hajontaparametrin estimaatti on $\phi \approx 6000 (> 1)$. Tämä viittaa siihen, että havaintoaineiston vaihtelu on huomattavasti suurempaa kuin mallin oletusten perusteella odotettaisiin, eikä malli näin ollen kuvaa aineistoa riittävän hyvin.

Mallin sopivuutta havainnollistetaan vertaamalla estimoituja ja havaittuja arvoja hajontakuviossa 4.1. Kuvaajasta nähdään, että valittu kolmiulotteinen malli kuvaa aineistoa selvästi paremmin kuin aiemmin tarkasteltu kaksiulotteinen malli kuvaajassa 2.4.




Kuva 4.1: Hajontakuviot havaituista ja estimoiduista frekvensseistä valitussa kolmiulotteisessa log-lineaarisessa mallissa.

Valitun kolmiulotteisen mallin residuaaleja tarkastellaan taulukossa 4.2, jossa esitetään ensin solun indeksi ja sen jälkeen vastaava residuaali. Residuaalien havaitaan olevan selvästi pienempiä samoilla indekseillä kuin taulukossa 2.9, mikä osoittaa valitun mallin parantavan sovitusta huomattavasti aiempaan malliin verrattuna.

Aiemmin taulukossa 2.9 tarkasteltujen solujen lisäksi taulukossa esiintyvät myös solut [705], joka vastaa luokkaa E00–E90, julkinen sektori, vuosi 2024, Helsingin kaupunki, sekä [930], joka vastaa luokkaa F00–F99, julkinen sektori, vuosi 2024, Helsingin kaupunki.

Taulukko 4.2: 5 itseisarvoltaan suurinta valitun mallin residuaalia.

	Pearson	devianssi	standardi
1.	[4530] 614,94	[4530] 469,44	[4530] 619,09
2.	[4555] 592,43	[4555] 453,65	[4555] 600,87
3.	[4505] 541,01	[4505] 423,58	[4505] 548,91
4.	[705] 536,86	[705] 388,38	[705] 540,48
5.	[930] 494,15	[930] 359,51	[930] 497,48

**Kuva 4.2:** Pearsonin residuaalit kolmiulotteisen mallin sovituksen arvioimiseksi.

Tarkastellaan Pearsonin residuaaleja vielä kuvaajassa 4.2. Residuaalikuvaajaa tulkitaan samalla tavalla kuin kuvaajaa 2.5. Valitun mallin tapauksessa residuaalit sijoittuvat huomattavasti satunnaisemmin nollan ympärille kuin aiemmassa kaksiulotteisessa mallissa, mikä viittaa parempaan sovitukseen. Kuvaajassa on kuitenkin edelleen nähtävissä joitakin huonoon sopivuuteen viittaavia piirteitä, kuten kuvaajan loppupäähän muodostuvat pylväsmäiset rakenteet.

4.2 NELIULOTTEISTEN RISTIINTAULUKOIDEN MALLINNUS

Neljän faktorimuuttujan log-lineaarisessa mallinnuksessa tarkasteltiin muuttujien välistä riippuvuusrakennetta. Analyysin tulokset esitetään taulukossa 4.3. Riippumattomuusmalli sopi aineistoon erittäin huonosti. Kolmesuuntaisten interaktioi-

den lisääminen pienensi devianssia $598633 - 103421 = 495212$, samalla kun vapausasteet vähenivät $4113 - 2546 = 1567$. Devianssin suhteellisen suuri pieneminen osoittaa, että kolmesuuntaiset interaktiot ovat aineiston riippuvuusrakenteen kuvaamisen kannalta olennaisia.

Malleja olisi ollut mahdollista laajentaa edelleen esimerkiksi vähentämällä useampia interaktiotermejä, mutta tässä tarkastelussa esitettiin selkeyden vuoksi keskeiset mallit, joissa yksittäisten yhteyksien vaikutusta voitiin arvioida systemaattisesti. Lisäksi kolmesuuntaisia interaktioita olisi ollut mahdollista tarkastella osittain.

Tulosten perusteella havaitaan, että yhteydet diagnoosi–hyvinvointialue, palvelusektori–hyvinvointialue sekä diagnoosi–palvelusektori ovat keskeisiä, sillä näiden interaktioiden puuttuminen johtaa selvästi suurempiin yhteensopivuustestisuureisiin (G^2 ja X^2), mikä viittaa heikompaan mallin sopivuuteen.

Kolmesuuntaisten interaktioiden mallia verrattiin vielä täyteen malliin, jolloin devianssin muutos oli $103421 - 77613 = 25808$ ja vapausasteiden muutos $2546 - 1584 = 962$. Neljännen interaktion lisääminen parantaa sopivuutta suhteellisesti selvästi vähemmän kuin aiemmassa vaiheessa, vaikka samalla mallin monimutkaisuus kasvaa huomattavasti. Näin ollen kaikki kolmesuuntaiset interaktiot sisältävää mallia $[DPV][DPH][DVH][PVH]$ voidaan pitää aineiston kannalta riittävän hyvänä mallina.


Taulukko 4.3: Log-lineaarisia malleja neliulotteiselle ristiintaulukolle.

Malli	G^2	X^2	Vapausasteet
$[D][P][V][H]$	12 160 023	13 782 652	4753
$[DP][DH][VP][VH][PH]$	773 921	778 444	4134
$[DP][DV][VP][VH][PH]$	1 484 996	1 553 334	4616
$[DP][DV][DH][VH][PH]$	832 494	837 649	4115
$[DP][DV][DH][VP][PH]$	641 728	645 005	4137
$[DP][DV][DH][VP][VH]$	4 196 693	4 213 057	4161
$[PH][DV][DH][VP][VH]$	6 101 613	5 958 421	4155
$[DP][DV][DH][PV][PH][VH]$	598 633	603 175.9	4113
$[DPV][DPH][DVH][PVH]$	103 421	103 287.6	2546
$[DPVH]$	77 613	78 277.7	1584

Valitussa mallissa esiintyy jälleen ylihajontaa $\phi \approx 40(> 1)$. Ylihajonnan kompensoimiseksi aineistoon sovitettiin valittu malli käyttämällä quasi-Poissonia Poissonin sijaan. Quasi-Poisson korjaa Poissonin saamia keskivirheitä ja p-arvoja ylihajonnan tapauksessa, muttei vaikuta mallin sovittamiin arvoihin tai devianssiin. [4]

Esitetään valitun mallin estimoidut arvot jälleen hajontakuviassa 4.3. Kuviosta huomataan, kuinka suuri vaikutus neljännen faktorimuuttujan lisäämisellä on aineiston mallinnuksessa, kun tätä verrataan aiempiin kuvaajiin 2.4 ja 4.1. Arvot si-

jaitsevat likimain suoraa pitkin eli voidaan todeta mallin sopivan aineistoon huomattavasti aiempaa paremmin.



Kuva 4.3: Hajontakuvi havaituista ja estimoiduista frekvensseistä valitussa neliulotteisessa log-lineaarisessa mallissa.

Esitetään vielä valitun neliulotteisen mallin suurimmat residuaalit taulukossa 4.4. Myös residuaalit ovat pienentyneet huomattavasti aiempiin tarkasteluihin verrattuna, mikä kertoo mallin paremmasta sopivuudesta. Solujen indeksit ovat jälleen merkitty hakasulkeilla.

Taulukko 4.4: 5 itseisarvoltaan suurinta valitun mallin residuaalia.


	Pearson	devianssi	standardi
1.	[1828] 41,74	[1828] 44,09	[1828] 51,13
2.	[703] 39,61	[703] 41,93	[703] 48,57
3.	[1171] 35,78	[1171] 33,85	[1196] 46,83
4.	[707] 32,71	[707] 30,84	[1171] 43,84
5.	[1832] 28,77	[1196] 29,94	[728] 42,25

Neliulotteisen mallin suurimpia residuaaliarvoja vastaavat selitteet on esitetty taulukossa 4.5. Selitteissä korostuu jälleen julkinen sektori, mutta tällä kertaa myös muita hyvinvointialueita kuin Helsinki.

Tarkastellaan residuaaleja vielä kuvaajassa. Residuaalikuvaajan 4.4 alussa esiintyy viuhkamaisuutta, mutta sen jälkeen residuaalit ovat jakautuneet satunnaisesti

Taulukko 4.5: Neliulotteisen valitun mallin suurimpia residuaaleja vastaavat havaintoyhdistelmät.

Indeksi	Diagnoosi	Sektori	Vuosi	Alue
1828	I00-I99	Julkinen	2024	Etelä-Pohjanmaa
703	E00-E90	Julkinen	2024	Etelä-Pohjanmaa
1171	G00-G99	Julkinen	2024	Satakunta
1196	G00-G99	Julkinen	2025	Satakunta
707	E00-E90	Julkinen	2024	Kainuu
1832	I00-I99	Julkinen	2024	Kainuu
728	E00-E90	Julkinen	2025	Etelä-Pohjanmaa



Kuva 4.4: Pearsonin residuaalit neliulotteisen mallin sovituksen arvioimiseksi.

suoran ympärille. Kuvaajassa näkyy ensimmäistä kertaa haluttua rakennetta, min-
kä vuoksi voidaan todeta mallin parantavan ennusteita huomattavasti edellisiin
malleihin verrattuna.

5 YHTEENVETO

Poissonin log-lineaarisen mallinnuksen tarkoituksena oli tutkia riippuvuuksia aineiston faktorimuuttujien välillä. Mallinnus toteutettiin kahden, kolmen ja neljän faktorin tapauksessa, ja analyysi aloitettiin valitsemalla riittävän hyvä malli yhteensopivuustestisuureiden perusteella. Tämän jälkeen valittujen mallien estimoituja arvoja verrattiin havaittuihin arvoihin hajontakuvioiden avulla.

Lisäksi jokaisen mallin kohdalla residuaaleja tarkasteltiin usealla eri menetelmällä. Tarkastelun perusteella tunnistettiin eniten havainnoista poikkeavia kategorioita, kuten Helsingin kaupunki ja julkinen sektori. Residuaalien käyttäytymistä havainnollistettiin myös kuvaajilla.

Kaksiulotteisessa mallinnuksessa parhaaksi malliksi valittiin interaktiotermien sisältävä malli, sillä se kuvasi aineistoa riippumattomuusmallia paremmin ANOVA-testin perusteella. Tarkastelussa olivat faktorit vuosi ja palvelusektori. Mallin estimoidut arvot erosivat kuitenkin selvästi havaituista arvoista, minkä vuoksi analyysia laajennettiin kolmannen faktorin sisältävään malliin.

Tähän vaiheeseen lisättiin kolmas faktori, diagnoosi. Valittiin malli, joka sisälsi kaikki kaksisuuntaiset interaktiot, koska se kuvasi muuttujien välisiä riippuvuuksia riittävän hyvin ilman tarpeettoman monimutkaista rakennetta. Devianssin ja vapausasteiden muutokset osoittivat, että valittu malli paransi sovitusta selvästi. Residuaalianalyysin perusteella suurimmat poikkeamat havaittujen ja estimoitujen arvojen välillä pienenivät merkittävästi kaksiulotteiseen malliin verrattuna. Tämän jälkeen analyysia laajennettiin lisäämällä vielä neljäs muuttuja, hyvinvointialue.

Neljännän muuttujan lisäämisen jälkeen todettiin, että riippumattomuusmalli ei kuvaa aineistoa riittävästi. Aineistoon sovitettiin kaksi- ja kolmisuuntaisia interaktioita sisältäviä malleja. Kolmesuuntaiset interaktiot pienensivät devianssia ja vapausasteita merkittävästi, mikä viittasi siihen, että vähintään nämä riippuvuusrakenteet on sisällytettävä malliin.

Mallia verrattiin vielä täyteen malliin varmuuden vuoksi. Lopulta päädyttiin kolmen interaktion malliin, sillä neljännän interaktion lisääminen ei parantanut sovitusta enää tarpeeksi, kun huomioitiin mallin monimutkaistuminen. Hajontakuvio osoitti, että estimoidut arvot vastasivat jo hyvin havaittuja arvoja. Lisäksi residuaalit olivat selvästi aiempia vaihteita pienempiä, mikä näkyi myös residuaalikuvaajassa.

Tuloksiin vaikutti erityisesti aineiston suuri koko, minkä vuoksi testisuureiden tulkinta poikkesi tavanomaisista viitearvoista. Log-lineaarisen mallinnuksen haasteena on mallin monimutkaistuminen muuttujien määrän kasvaessa. Jo neljän muuttujan tapauksessa analyysin tulkinta ja laskennallinen toteutus alkoivat vaikeutua aineiston laajuuden vuoksi.

Residuaalianalyysissä nousivat useassa vaiheessa esiin julkinen sektori ja Helsingin kaupunki, mikä viittaa siihen, että näissä kategorioissa havaittiin suurta vaihtelua ja mallin selitysvoima oli heikompi. Analyysin tulokset viittasivat siihen, että

diagnoosin ja palvelusektorin välillä esiintyi riippuvuutta, mikä voi kertoa eroista palveluiden käytössä tai diagnosointikäytännöissä. Lisäksi neliulotteisen ristiintaulukon analyysissä nousi esiin riippuvuuksien diagnoosi–hyvinvointialue, palvelusektori–hyvinvointialue ja diagnoosi–palvelusektori merkittävyys.

Log-lineaarinen mallinnus soveltui aineiston analysointiin hyvin sen kategorisen luonteen vuoksi. Tulosten luotettavuutta heikensi kuitenkin aineistossa havaittu voimakas ylihajonta, mikä tarkoittaa, että havaintojen vaihtelu oli suurempaa kuin Poisson-oletus edellyttäisi. Tämä voi johtaa keskivirheiden aliarviointiin ja liian optimistisiin merkitsevyystasoihin.

LÄHTEET

- [1] A. Agresti, *Foundations of linear and generalized linear models*, 1. painos. John Wiley ja Sons Inc, 2015.
- [2] A. Agresti, *An Introduction to Categorical Data Analysis*, 3. painos. Wiley, 2019.
- [3] R. Christensen, *Log-linear models and logistic regression*, 2. painos. New York: Springer, 1997.
- [4] M. J. Crawley, "Count Data," teoksessa *The R Book*, John Wiley ja Sons Inc, 2012, s. 579–598.
- [5] S. E. Fienberg, *The Analysis of Cross-Classified Categorical Data*, 2. painos. Springer New York, 2007.
- [6] W. Gardner, E. P. Mulvey ja E. C. Shaw, "Regression analyses of counts and rates: Poisson, overdispersed poisson, and negative binomial models," *Psychological bulletin*, vol. 118, nro 3, s. 392–404, 1995.
- [7] J. M. V. Hoef ja P. L. Boveng, "Quasi-poisson vs. negative binomial regression: How should we model overdispersed count data?" *Ecology*, vol. 88, nro 11, s. 2766–2772, 2007.
- [8] P. Holopainen Martti ja Pulkkinen, *Tilastolliset menetelmät*, 5.–8. painos. Sanoma Pro Oy, 2013.
- [9] D. Knoke ja P. J. Burke, *Log-linear models*, 1. painos. Sage Publications, 1980.
- [10] J. K. Lindsey, *Modelling frequency and count data*, 1. painos. Oxford University Press Inc, 1995.
- [11] P. Martin, *Regression models for categorical and count data*, 1. painos. SAGE Publications Ltd, 2021.
- [12] P. McCullagh ja J. A. Nelder, *Generalized Linear Models*, 2. painos. Taylor ja Francis, an imprint of Routledge, 2019.
- [13] N. Nasseruddin, Z. Mahmud ja K. A. Md Isa, "Modeling tuberculosis patients using loglinear models," *Journal of physics*, vol. 1366, nro 1, s. 2–4, 2019.
- [14] "Perusterveydenhuollon avohoidon, työterveyshuollon ja kotihoidon asiakkaiden käyntidiagnoosit ja pitkäaikaissiagnoosit hyvinvointialueittain." (12. helmikuuta 2025), url: https://sampo.thl.fi/pivot/prod/fi/avo/perus14/fact_ahil_perus14?row=aika-87596&column=icd10-396870&column=sektori-617728&column=alue-11810 (viitattu 14. 05. 2026).
- [15] W. Tang, H. He ja X. M. Tu, *Applied categorical and count data analysis*, 2. painos. CRC Press, 2023.
- [16] G. J. G. Upton, *Categorical Data Analysis by Example*, 1. painos. John Wiley ja Sons Inc, 2016.
- [17] A. Von Eye ja E.-Y. Mun, *Log-linear modeling : concepts, interpretation and application*, 1. painos. Wiley-Blackwell, 2013.
- [18] X. Yan ja X. Su, *Linear regression analysis : theory and computing*, 1. painos. World Scientific, 2009.

LIITE A: R-KOODIT

```
## Aineiston muokkaus analyysiin sopivaksi

library(tidyr)
library(dplyr)

top <- as.character(raaka[1, ])
bottom <- as.character(raaka[2, ])

# Yhdistetään otsikkorivit: hyvinvointialue_vuosi
names(raaka) <- ifelse(
  is.na(bottom),
  top,
  paste(top, bottom, sep = "_")
)
# Poistetaan alkuperäiset otsikkorivit
raaka <- raaka[-c(1,2), ]

# Aineisto pitkään muotoon
diag_long <- raaka %>%
  pivot_longer(
    cols = -c(Potilaat, Sektori),
    names_to = c("Vuosi", "Hyvinvointialue"),
    names_sep = "_",
    values_to = "Lukumäärä"
  )

diag_long <- subset(diag_long, Potilaat !=
  "Kaikki diagnoosit (ICD-10)" )

# Poistaa kaikki muut kuin numerot
diag_long$Lukumäärä <- as.numeric(
  gsub("[^0-9]", "", diag_long$Lukumäärä))
diag_long$Vuosi <- as.integer(diag_long$Vuosi)

## Kolmiulotteinen mallinnus
# riippumaton malli
# malli_ind <- glm(Lukumäärä ~ Potilaat + Vuosi +
  Sektori, data = diag_long, family = poisson)

# Sektori-vuosi interaktio
# malli_sv <- glm(Lukumäärä ~ Potilaat + Vuosi *
  Sektori, data = diag_long, family = poisson)

# Sektori-diagnoosi interaktio
# malli_sd <- glm(Lukumäärä ~ Potilaat * Sektori
  + Vuosi, data = diag_long, family = poisson)

# Vuosi-diagnoosi interaktio
# malli_vd <- glm(Lukumäärä ~ Potilaat * Vuosi
  + Sektori, data = diag_long, family = poisson)
```

```

# Ehdollisen riippumattomuuden mallit
malli_svsvd <- glm(Lukumäärä ~ Potilaat + Vuosi
* Sektori + Potilaat * Sektori, data = diag_long,
family = poisson)

malli_vsvd <- glm(Lukumäärä ~ Sektori + Vuosi
* Sektori + Potilaat * Vuosi, data = diag_long,
family = poisson)

malli_dsvd <- glm(Lukumäärä ~ Vuosi + Potilaat
* Sektori + Potilaat * Vuosi, data = diag_long,
family = poisson)

# Kaikki kaksisuuntaiset interaktiot
malli_int <- glm(Lukumäärä ~ Potilaat * Vuosi
+ Vuosi * Sektori + Potilaat * Sektori, data =
diag_long, family = poisson)

# Täysi malli
malli_sat <- glm(Lukumäärä ~ Potilaat * Vuosi
* Sektori, data = diag_long, family = poisson)

## Neliulotteinen mallinnus

# Riippumaton malli
malli_ind <- glm(Lukumäärä ~ Potilaat + Vuosi
+ Sektori + Hyvinvointialue, data = diag_long,
family = poisson)

# Ilman yhteyttä Diagnoosi-Vuosi
malli_ilmanPV <- glm(Lukumäärä ~ Potilaat + Vuosi
+ Sektori + Hyvinvointialue + Potilaat:Sektorit +
Potilaat:Hyvinvointialue + Vuosi:Sektorit +
Vuosi:Hyvinvointialue + Sektori:Hyvinvointialue,
data = diag_long, family = poisson)

# Ilman yhteyttä Diagnoosi-Hyvinvointialue
malli_ilmanPA <- glm(Lukumäärä ~ Potilaat + Vuosi
+ Sektori + Hyvinvointialue + Potilaat:Sektorit +
Potilaat:Vuosi + Vuosi:Sektorit +
Vuosi:Hyvinvointialue + Sektori:Hyvinvointialue,
data = diag_long, family = poisson)

# Ilman yhteyttä Vuosi-Palvelusektori
malli_ilmanVS <- glm(Lukumäärä ~ Potilaat + Vuosi
+ Sektori + Hyvinvointialue + Potilaat:Sektorit +
Potilaat:Vuosi + Potilaat:Hyvinvointialue +
Vuosi:Hyvinvointialue + Sektori:Hyvinvointialue,
data = diag_long, family = poisson)

# Ilman yhteyttä Vuosi-Hyvinvointialue
malli_ilmanVA <- glm(Lukumäärä ~ Potilaat + Vuosi
+ Sektori + Hyvinvointialue + Potilaat:Sektorit +
Potilaat:Vuosi + Potilaat:Hyvinvointialue +
Vuosi:Sektorit + Sektori:Hyvinvointialue,
data = diag_long, family = poisson)

```

```

# Ilman yhteyttä Palvelusektori-Hyvinvointialue
malli_ilmanSA <- glm(Lukumäärä ~ Potilaat + Vuosi
+ Sektori + Hyvinvointialue + Potilaat:Sektori +
Potilaat:Vuosi + Potilaat:Hyvinvointialue +
Vuosi:Sektori + Vuosi:Hyvinvointialue,
data = diag_long, family = poisson)

# Ilman yhteyttä Diagnoosi-Palvelusektori
malli_ilmanPS <- glm(Lukumäärä ~ Potilaat + Vuosi
+ Sektori + Hyvinvointialue + Sektori:Hyvinvointialue
+ Potilaat:Vuosi + Potilaat:Hyvinvointialue +
Vuosi:Sektori + Vuosi:Hyvinvointialue,
data = diag_long, family = poisson)

# Kaikki kaksisuuntaiset interaktiot
malli_2int <- glm(Lukumäärä ~ (Potilaat + Vuosi +
Sektori + Hyvinvointialue)^2, data = diag_long,
family = poisson)

# Kaikki kolmisuuntaiset interaktiot
malli_3int <- glm(Lukumäärä ~ (Potilaat + Vuosi +
Sektori + Hyvinvointialue)^3, data = diag_long,
family = poisson)

# Täysi malli
malli_sat <- glm(Lukumäärä ~ Potilaat * Vuosi *
Sektori * Hyvinvointialue, data = diag_long,
family = poisson)

## Residuaalit
pearson.resid <- resid(malli, type = "pearson")
deviance.resid <- resid(malli, type = "deviance")
std.resid <- rstandard(malli, type = "pearson")

```

LIITE B: AINEISTON MUUTTUJAT

B.0.1 DIAGNOOSIT

A00-B99 Tartunta- ja loistauteja

C00-D48 Kasvaimet

D50-D89 Veren ja verta muodostavien elinten sairaudet sekä eräät immuunimekanismin häiriöt

E00-E90 Umpierityssairaudet, ravitsemussairaudet ja aineenvaihduntasairaudet

F00-F99 Mielenterveyden ja käyttäytymisen häiriöt

G00-G99 Hermoston sairaudet

H00-H59 Silmän ja sen apuelinten sairaudet

H60-H95 Korvan ja kartiolisäkkeen sairaudet

I00-I99 Verenkierroelinten sairaudet

J00-J99 Hengityselinten sairaudet

K00-K93 Ruuansulatuselinten sairaudet

L00-L99 Ihon ja ihonalaiskudoksen sairaudet

M00-M99 Tuki- ja liikuntaelinten sekä sidekudoksen sairaudet

N00-N99 Virtsa- ja sukupuolielinten sairaudet

O00-O99 Raskaus, synnytys ja lapsivuoteus

P00-P96 Eräät perinataaliaikana alkaneet tilat

Q00-Q99 Synnynnäiset epämuodostumat, epämuotoisuudet ja kromosomipoikkeavuudet

R00-R99 Muualla luokittamattomat oireet, sairaudenmerkit sekä poikkeavat kliiniset ja laboratoriolöy

S00-T98 Vammat, myrkytykset ja eräät muut ulkoisten syiden seuraukset

U00-U99 Diagnoosikoodeja erityistapauksille

Z00-ZZB Tekijöitä jotka vaikuttavat terveydentilaan ja yhteydenottoihin terveyspalvelujen tuottajiin

Tuntematon koodi

B.0.2 HYVINVOINTIALUEET

Ahvenanmaa

Etelä-Karjalan hyvinvointialue

Etelä-Pohjanmaan hyvinvointialue

Etelä-Savon hyvinvointialue

Helsingin kaupunki

Itä-Uudenmaan hyvinvointialue

Kainuun hyvinvointialue

Kanta-Hämeen hyvinvointialue

Keski-Pohjanmaan hyvinvointialue

Keski-Suomen hyvinvointialue

Keski-Uudenmaan hyvinvointialue

Kymenlaakson hyvinvointialue

Lapin hyvinvointialue

Länsi-Uudenmaan hyvinvointialue

Pirkanmaan hyvinvointialue

Pohjanmaan hyvinvointialue

Pohjois-Karjalan hyvinvointialue

Pohjois-Pohjanmaan hyvinvointialue

Pohjois-Savon hyvinvointialue

Päijät-Hämeen hyvinvointialue

Satakunnan hyvinvointialue

Vantaan ja Keravan hyvinvointialue

Varsinais-Suomen hyvinvointialue

Ulkomaat

Tieto puuttuu